

LLMを用いた家庭用移動ロボットのナビゲーションシステムの 開発と評価

2025

修士(工学)

情報・知能工学専攻

白谷 歩夢

223333

指導教員: 垣内 洋平

豊橋技術科学大学

概要

本論文は、大規模言語モデル (Large Language Model; LLM) の知識と推論能力を活用し、動的・未知障害物を含む家庭環境において、移動ロボットが周囲の歩行者に不安を与えにくい自然な経路選択および移動挙動を実現するナビゲーション手法の構築を目的とする。

家庭内では、人の往来や障害物配置の変化、見通しの悪い通路などにより、従来の地図・コストマップに基づくナビゲーションのみでは、状況に応じた局所的な経路修正を安定して行うことが難しい。また、動的障害物を含む環境で手法を検討・評価するためには歩行者の存在を想定した状況設定が不可欠であるが、歩行者挙動を単純な力学モデルのみに依存して与える場合、状況に応じた多様な回避挙動を十分に表現できない可能性がある。さらに、LLM を実行時に直接用いることは応答時間・計算資源の制約から現実的でない。

そこで本研究では、LLM をオンラインの意思決定器として用いるのではなく、LLM をオフラインの教師信号生成に用い、その判断を学習済みの軽量モデルへ転移する方針をとる。具体的には、視点画像と補正前経路を入力として LLM に補正後経路を生成させ、その結果を教師データとして画像認識モデルを学習することで、実行時には軽量モデルのみで局所的な経路修正を可能にする。また、歩行者役エージェント (actor) についても、ロボットと同様に視覚情報に基づく局所的な経路修正を学習により実現する枠組みを適用し、すれ違い場面において違和感の少ない挙動生成を目指す。ただし、本論文における actor とロボットは同一の学習枠組みに基づく一方で、目的と評価系が異なるため、両者は独立に比較・評価する。

評価では、(i) 画像認識モデルが LLM の経路修正傾向をどの程度再現できるか、(ii) actor の挙動がすれ違い場面で違和感の少ないものとして知覚されるか、(iii) 実機ロボットが対人場面で不安や怖さを与えにくい走行を実現できるか、を中心に検討する。あわせて、客観評価と主観評価の両面から提案手法をベースラインと比較し、LLM を実行時に直接用いるのではなく、判断を学習可能な形で取り出して高速系へ移す設計が、家庭用移動ロボットの動的・未知障害物下の経路選択をどこまで改善し得るかを明らかにする。

This thesis aims to construct a navigation method that enables a mobile robot to achieve natural path selection and motion behavior that are less likely to cause anxiety to surrounding pedestrians in a home environment including dynamic and unknown obstacles, by leveraging the knowledge and reasoning capability of a Large Language Model (LLM).

In a household environment, due to human traffic, changes in obstacle placement, and corridors with poor visibility, it is difficult for navigation based only on conventional maps and costmaps to stably perform local path corrections according to the situation. In addition, in order to examine and evaluate navigation methods in environments with dynamic obstacles, it is essential to set up situations that assume the presence of pedestrians; however, if pedestrian behavior is given only by a simple dynamics-based model, it may not be possible to sufficiently represent diverse avoidance behaviors depending on the situation. Furthermore, using an LLM directly at runtime is not realistic due to constraints on response time and computational resources.

Therefore, in this thesis, instead of using the LLM as an online decision maker, we use the LLM for offline generation of teacher signals and transfer its decisions to a lightweight trained model. Specifically, the LLM generates a corrected path from an input of an egocentric image and an uncorrected path, and we train an image recognition model using the results as training data; this enables local path correction at runtime using only the lightweight model. We also apply the same

framework to a pedestrian agent (actor), as for the robot, to realize local path correction based on visual information by learning, and aim to generate behavior with low perceived unnaturalness in passing-by situations. However, in this thesis, although the actor and the robot are based on the same learning framework, their objectives and evaluation setups are different, so we compare and evaluate them independently.

In the evaluation, we mainly examine (i) to what extent the image recognition model can reproduce the path-correction tendency of the LLM, (ii) whether the actor's behavior is perceived as having low unnaturalness in passing-by situations, and (iii) whether the real robot can achieve motion that is less likely to cause anxiety or fear in human-robot interaction scenes. In addition, we compare the proposed method with baseline methods from both objective and subjective evaluations, and clarify how much the design of not using the LLM directly at runtime, but extracting its decisions in a learnable form and moving them to a fast system, can improve path selection for a home mobile robot under dynamic and unknown obstacles.

目次

1 序論	5
1.1 研究の背景と目的	5
1.2 関連研究	5
1.3 本論文の構成	8
2 システム概要	9
2.1 システム全体構成	9
2.2 ロボットプラットフォーム	9
2.3 actor と環境モデルの定義	10
2.4 シミュレーション環境と実機環境の対応	10
3 LLM に基づく行動生成手法	14
3.1 教師信号生成における LLM 利用の位置づけ	14
3.2 入力情報の設計	14
3.3 プロンプト設計（教師信号生成の指示）	15
3.4 出力形式の設計	16
3.5 actor に対する教師信号生成	16
3.6 ロボットに対する教師信号生成	16
4 画像認識モデルの学習	18
4.1 学習の位置づけ	18
4.2 学習データセットの構成	18
4.3 モデル入出力と教師表現	19
4.4 学習手順と損失関数	19
4.5 推論時の後処理と waypoint 生成	20
4.5.1 後処理なし（単純復元）	20
4.5.2 後処理あり（行方向平滑化）	20
4.5.3 実空間座標系への変換	21
4.6 評価指標（モデルの評価）	21
5 actor の行動生成	23
5.1 actor の役割と設計方針	23
5.2 actor の入出力と制御ループの概要	23
5.3 比較対象 1：SFM に基づく actor	24
5.4 比較対象 2：画像認識モデルによる経路補正 actor	24
5.5 実装（シミュレーション内での actor 制御）	24
5.6 評価の位置づけ	24
6 ロボットの行動生成（ナビゲーション）	26
6.1 ロボットの役割と設計方針	26
6.2 ロボットの入出力と制御ループの概要	26
6.3 比較対象 1：move_base に基づくナビゲーション	26

6.4	比較対象 2：画像認識モデルによる局所経路補正ナビゲーション	27
6.5	実装（実機内でのロボット制御）	27
6.6	評価の位置づけ	27
7	実験および評価	28
7.1	実験設定	28
7.1.1	評価の目的と位置づけ	28
7.1.2	被験者	28
7.1.3	条件設計と試行数	28
7.1.4	評価指標	28
7.1.5	アンケート設計	28
7.1.6	本章の構成	29
7.2	画像認識モデルの性能評価	29
7.2.1	実験方法	29
7.2.2	結果	30
7.2.3	考察	30
7.3	リアルタイム性評価	33
7.3.1	実験方法	33
7.3.2	結果と考察	33
7.4	actor 挙動に対する主観評価	35
7.4.1	実験方法	35
7.4.2	結果と考察	36
7.5	ロボット挙動に対する主観評価	38
7.5.1	結果と考察	39
7.6	実機実験における定量評価	40
7.6.1	実験方法	41
7.6.2	結果と考察	41
8	結論	42
8.1	まとめ	42
8.2	今後の課題と展望	43
A	付録：プロンプト全文	47
A.1	actor 用プロンプト	47
A.2	robot 用プロンプト	50
B	予備審査時の質疑への回答	55

1 序論

1.1 研究の背景と目的

視覚障がい者は、壁や障害物、曲がり角といった空間情報を離れた場所から視覚的に得ることが難しく、自力で安全かつ効率的に移動することが困難である。そのため、白杖や点字ブロック、ナビゲーションアプリ、介助者による誘導など、移動を支援する手段が発展してきた。中でも盲導犬は、障害物回避や段差検知などを通して利用者の安全な移動を支援する手段として有効である。

一方で、盲導犬には供給数や運用コストの課題があり、需要に対して十分とは言えない。また、信号機の色や識別や、出発地から目的地までを見通した経路全体の案内は困難であり、状況に応じたルート選択・変更の最終判断は利用者に委ねられる。このため、盲導犬を代替・補完する移動支援手段の検討は依然として重要である。

この状況を踏まえ、本研究では家庭用移動ロボットを用いたナビゲーションシステムに着目する。著者の先行研究 [1] では、ロボットがユーザの手を引いて先導し目的地まで誘導するシステムを提案したが、想定環境は静的かつ既知の障害物に限定されており、歩行者や未知物体などの動的・未知障害物を十分に扱えていなかった。しかし実際の生活空間では、人の往来や家具配置の変更など、事前に完全には把握できない要因が常在し、この前提は実環境から乖離している。

そこで本研究は、大規模言語モデル (Large Language Model; LLM) の知識と推論能力を活用し、動的・未知障害物を含む家庭環境において、移動ロボットが安全かつ自然な経路でユーザを誘導できるナビゲーションシステムの構築を目的とする。ただし、LLM を実行時に直接用いることは応答時間・計算資源の制約から現実的でないため、本研究では LLM をオフラインの教師信号生成に用い、その判断を学習済みの軽量モデルへ転移 (知識蒸留の考え方) する方針をとる。具体的には、視点画像と補正前経路を入力として LLM に「安全な通行を満たす補正後経路」を生成させ、その結果を教師データとして画像認識モデルを学習することで、実行時には軽量モデルのみで局所的な経路修正を可能にする。

一方、動的障害物を含む環境でナビゲーション手法を検討・評価するためには、歩行者の存在を想定した状況設定が不可欠である。このとき、歩行者挙動を単純な力学モデルのみに依存して与える場合、状況に応じた多様な回避挙動を十分に表現できない可能性がある。そこで本研究では、歩行者役エージェント (actor) についても、ロボットと同様に視覚情報に基づく局所的な経路修正を学習により実現する枠組みを適用し、主観的に違和感の少ない挙動生成を目指す。

ただし、本論文における actor とロボットは、いずれも同一の学習枠組みに基づく一方で、目的と評価系が異なるため、両者は独立に比較・評価する。具体的な実験条件および評価方法の詳細は第 7 章に示す。本論文の到達目標は、(i) LLM を用いた教師信号生成と軽量モデル学習からなる経路補正の枠組みを整理し、(ii) actor に対して主観的に違和感の少ない挙動生成が可能であることを確認し、(iii) 衝突回避などの物理的安全性は既存手法により担保されていることを前提として、実機ロボットが対人場面で人に不安や怖さを与えにくい心理的安全性を備えた走行を実現できるかを、ベースライン手法との比較により検討することである。

1.2 関連研究

屋内を移動する台車ロボット (wheeled mobile robot) の自律移動に関する研究は、地図生成 (SLAM) や経路計画を基盤とし、レーザセンサ等による自己位置推定と組み合わせたナビゲーションシステムの構築によって着実に発展してきた。例えば Huang らは、従来の Gmapping アルゴ

リズムを改良し、さらに双方向探索を行う Bidirectional A* を導入することで、複雑な屋内環境においても安定かつ高速な経路計画が可能であることを示している [2]。また Wu らは、超広帯域無線通信 (Ultra-Wide Band; UWB) と 5G 通信を併用した屋内測位手法を開発し、GPS を利用できない室内環境においてもセンチメートル単位の位置精度を実現することで、移動ロボットの自己位置推定の信頼性を向上させた [3]。これらの研究は主として静的、あるいはほぼ静的な環境での移動を対象としており、人や他のロボットといった動的障害物 (dynamic obstacles) を含む状況への対応は限定的である。

この制約を克服するため、歩行者 (人) の存在を考慮したロボットナビゲーションに関する研究も増加している。Senft らは、狭い通路環境において人とロボットがすれ違う状況を対象とし、人に対して社会的に受容されるような進路選択や速度調整を行う振る舞い生成手法を提案している [4]。このような研究は、ロボットが人と物理的に衝突しないだけでなく、人間側から見て「自然で違和感の少ない」挙動を実現することの重要性を示している。

また、ロボット側の制御ではなく、歩行者モデルそのものを対象とした研究も数多く存在する。代表的なものとして、Helbing と Molnár による Social Force Model (SFM) が挙げられる [5]。SFM では歩行者を質点とみなし、「目的地への駆動力 (desired-velocity force)」「他者や障害物からの回避力 (repulsive/social interaction force)」「揺らぎ (fluctuation)」といった複数の力の合成によって歩行者の運動を記述する。このモデルを用いた群集シミュレーションでは、レーン形成や群集流、出入口付近での渋滞など、実世界で観察される群集現象がある程度自然に再現できることが示されている。SFM をロボットナビゲーションに直接応用し、人とロボットの相互回避行動をモデル化した研究も報告されている [6]。しかしながら、SFM はあくまで力学的・社会的相互作用を抽象化したモデルであり、人間の多様な意図や認知、視界、意思決定といった高次の振る舞いを十分に表現できないという限界がある。そのため、後続研究では SFM の interaction の柔軟性を高める手法や、歩行者の認知や注意 (awareness) を導入するモデル、さらにはパラメータの調整や理論的枠組みの改善を試みる研究などが提案されているが、多様な個別挙動を汎用的に再現するにはいまだ不十分である [7][8][9]。

一方で、大規模言語モデル (Large Language Model; LLM) は、自然言語処理分野における基盤技術として急速に発展してきた。LLM とは、大量のテキストデータを用いた事前学習によって構築され、自然言語を入力として受け取り、文の続きを生成する形で応答を出力するニューラルネットワークである。このとき、単なる文章生成に留まらず、入力文脈にもとづく知識の利用や推論、指示の解釈といった高次の処理を行える点が特徴である。LLM は Transformer 構造に基づく大規模な事前学習によって構築され、大量のテキストデータから言語的知識や文脈理解能力を獲得する点に特徴がある。この Transformer 構造は、Vaswani らによって提案された Attention のみを用いる系列変換モデルに基づいており、長距離依存関係の効率的なモデリングと高い並列計算性能を実現した [10]。LLM の代表的な例として、Brown らによる GPT-3 は、タスク固有の追加学習を行わずとも、少数例提示 (few-shot learning) や指示文のみで多様な言語タスクを遂行可能であることを示した [11]。このようなモデルは、対話型 AI や文章生成といった用途に留まらず、推論や意思決定を含むより高次の情報処理にも応用されており、近年ではチャットボットをはじめとする幅広い分野で利用されている。

その後、LLM の枠組みに視覚情報を統合した Vision-Language Model (VLM) が提案され、画像と言語を同時に扱うことが可能となった。Radford らによる CLIP は、画像とテキストの対を用いた対照学習により、画像を言語表現と同一の埋め込み空間に写像する視覚エンコーダを学習し、視覚情報と言語情報を統合的に扱うための基盤的手法を示した [12]。このように、CLIP によって獲得された視覚表現は、自然言語による記述との直接的な対応付けを可能にし、画像分類や視覚的

質問応答といったタスクを、タスク固有の分類器に依らず柔軟に扱えることを示した。さらに近年では、このような視覚エンコーダを言語モデルと組み合わせることで、対話的な指示理解や推論能力を強化した VLM が提案されている。例えば Liu らによる LLaVA は、CLIP に基づく視覚エンコーダと大規模言語モデルを結合し、画像と自然言語指示を入力として、画像内容の説明や推論を行うことができるモデルであり、視覚情報を含む対話的タスクにおいて高い性能を示している [13]。また Bai らによる Qwen-VL は、大規模な画像-テキストデータを用いて学習された汎用 VLM であり、視覚的質問応答や空間的理解、画像に基づく推論など、多様なタスクに対応可能であることが報告されている [14]。これらの VLM は、単なる画像認識を超えて、画像を高次の意味表現へと変換し、言語モデルによる推論や対話に利用できる点で特徴的である。

しかし、高い性能は大規模なモデル構成と計算コストに依存しており、推論時のレイテンシや計算資源の制約から、実時間動作が求められるロボットシステムへの直接的な適用には課題が残る。このような課題に対する有効なアプローチとして、知識蒸留 (knowledge distillation) が広く用いられている。知識蒸留とは、高性能な大規模モデル (教師モデル) の出力分布や中間表現に含まれる知識を、小規模なモデル (生徒モデル) へ転移することで、性能を維持しつつ計算量を削減する学習手法であり、Hinton らによってその基本的枠組みが示された [15]。特に視覚分野では、物体検出をはじめとするタスクにおいて、高精度な大規模モデルを教師として用い、実時間性が要求される環境向けに軽量化モデルへと知識を転用する研究が数多く報告されている [16]。さらに、CLIP や LLaVA などの VLM を教師モデルとし、視覚と言語の対応関係や指示理解能力を小規模モデルへ蒸留する手法が提案されており、高度な視覚-言語理解能力を保持したまま、推論の高速化を実現できることが示されている [17]。これらの知識蒸留に基づくアプローチは、高性能な視覚-言語モデルを実環境のロボットシステムへ適用するための重要な基盤技術と位置づけられる。

このような VLM の発展や、それを実環境へ適用するための軽量化・高速化の試みを背景として、視覚・言語・行動を統合した Vision-Language-Action (VLA) モデルがロボット分野において注目されている。Brohan らは、インターネット規模の視覚-言語 (vision-language) データを利用して学習したモデルをロボット制御に転移する枠組み RT-2 を提案し、視覚入力から行動コマンドへの写像を学習によって実現することで、高い汎化性能と柔軟な動作生成を達成した [18]。また Gemini Robotics Team による Gemini Robotics 1.5 では、ロボットの操作タスクを対象として、高度な推論能力とモーション転移に基づく汎用ロボットの実現可能性が示されている [19]。このような視覚-言語-行動 (vision-language-action; VLA) モデルは、タスクの多様性や未知状況への適応力という点で優れており、歩行者を含む環境におけるロボット制御への応用可能性が示唆される。一方で、RT-2 や Gemini Robotics 1.5 をはじめとする関連研究の多くはマニピュレーション (把持や操作) やデモからのスキル獲得を主対象としており、台車ロボットが歩行者混在空間を移動するナビゲーション文脈への適用例は依然として限られている。

以上を踏まえると、従来の台車ロボットのナビゲーション研究は静的環境や静的障害物を主な対象としており、動的障害物としての歩行者を十分に扱えていないこと、また、VLA 型のロボット制御モデルは高い汎化能力を有する一方で、歩行者混在環境におけるナビゲーションへの応用事例が少ないことが分かる。さらに、SFM をはじめとする歩行者モデルは群集現象の再現に有効であるものの、人間の認知や意図、多様な個別挙動を表現するには限界がある。

そこで本研究では、大規模言語モデル (Large Language Model; LLM) が有する知識と推論能力に着目し、家庭用移動ロボットのナビゲーションにおける経路選択および動的障害物への対応を高度化することを目指す。最終的な目標は、ロボットの行動判断を LLM によって一貫して決定することであるが、現段階では、計算資源やリアルタイム性の制約から、LLM を推論時に直接用いることは現実的ではない。この課題に対し、本研究では知識蒸留の考え方を採用し、LLM の推論

結果を教師信号として用いることで、実時間動作が可能な軽量な視覚モデルを構築するという方針をとる。すなわち、LLM によって得られた経路選択や回避に関する判断を学習データとして利用することで、推論時には軽量なモデルのみを用いながら、LLM が有する知識や推論の効果を間接的に活用する。

また、本研究ではこの枠組みを、移動ロボットのナビゲーションだけでなく、歩行者役エージェント (actor) の行動生成にも適用する。両者は同一の学習枠組みに基づき、モデルの基本構造も共通とする一方で、視点条件や回避すべき対象が異なるため、それぞれの条件に基づいて生成したデータを用いて個別に学習・推論を行う。これにより、ロボットナビゲーションに対しては動的・未知障害物下での安全な走行の実現を、actor に対してはすれ違い場面において主観的に違和感の少ない挙動生成の実現を、それぞれ独立した課題として検討できるようにする。

本論文では、このような構成のもとで、actor についてはシミュレーション環境において、ロボットについては実機環境において、動的・未知障害物を含む状況下での挙動を評価し、LLM を活用した家庭用移動ロボットナビゲーションおよび歩行者行動生成の有効性と課題を明らかにする。

1.3 本論文の構成

本論文の構成を以下に示す。第2章ではシステム全体構成、使用するロボット、actor と環境モデル、および使用環境（シミュレーション／実機）と評価の対象を述べる。第3章では LLM に基づく教師信号生成（経路補正）手法と入出力設計を説明する。第4章では、生成した教師データを用いた画像認識モデルの学習手順とデータセット構成を述べる。第5章では actor の行動生成と比較対象を述べる。第6章ではロボットナビゲーションの設計と経路補正の導入点を述べる。第7章では実験と評価として、画像認識モデル自体の評価、actor のアンケート評価、ロボットのアンケート評価、およびロボットの数値評価に基づき、提案手法をベースラインと比較して有効性と課題を検討する。第8章では結論と今後の展望を述べる。

2 システム概要

2.1 システム全体構成

本研究で構築するシステムは、家庭環境シミュレーション環境、歩行者役エージェント (actor)、家庭用移動ロボット (HSR)、および教師データ生成に用いる大規模言語モデル (Large Language Model; LLM) から構成される。

本研究で扱う課題は、(i) actor の行動生成、および (ii) 移動ロボットのナビゲーションである。両者は目的と評価系が異なるため、本論文では独立に比較・評価する (評価方法の詳細は第 7 章に示す)。一方で、両課題には共通して「視覚入力に基づく局所的な経路修正」を導入するため、LLM を用いた教師信号生成と、軽量の画像認識モデルへの知識転移 (知識蒸留の考え方) からなる枠組みを採用する。モデルの基本構造は actor / ロボットで共通としつつ、視点条件 (カメラ位置) および回避すべき対象が異なるため、データセットおよび教師信号生成条件はそれぞれ個別に構築する。

LLM はシステム実行中には用いず、データセット作成時 (オフライン) のみに使用する。具体的には、actor / ロボットそれぞれの視点で取得されたカラー画像を入力として与え、安全な通行を満たすように補正した経路を座標列 (JSON 形式) として生成させる。このとき、補正対象となる補正前経路については、カメラ画像座標系で表した 2 次元点列をテキストとしてプロンプトに含め、座標情報に基づいて補正後経路を生成させる。また、深度画像から推定した床領域マスクを補助情報として併用し、LLM が床上の通行可能領域を考慮しやすいようにする (床領域マスクは画像認識モデルの入力ではなく、LLM による教師データ生成の補助として用いる)。床領域マスクは、シミュレーション上で取得できるカメラの位置・姿勢情報と Depth 画像を用い、床面を復元して生成する。なお、補正対象となる補正前経路は、入力視点から画像平面へ投影可能な点のみを用いる (投影できない区間は補正対象から除外する)。図 1 に知識転移の概要、図 2 にシステムの全体概要を示す。

2.2 ロボットプラットフォーム

本研究では、家庭用移動ロボットとして TOYOTA の生活支援ロボット HSR (Human Support Robot) を用いる (図 3)。なお、実験で用いる機体は HSR の個体 (HSRB) であるが、本論文では表記を HSR に統一する。HSR は、小回りの効く円筒型の小型・軽量ボディに折り畳み式アームを備え、家庭内における物体把持・搬送や見守り等、人の生活支援を目的として設計されている。また、人に触れることを前提として、安全に利用できるように駆動部に大きな力が生じないよう配慮されている。

HSR には、移動・周辺認識・安全確保のために複数のセンサが搭載されている。代表例として、レーザ測域センサ (UST-20LX)、IMU (6DOF)、停止用の磁気式センサ (N 極検知型)、6 軸力覚センサ、RGB-D センサ (Xtion PRO LIVE)、ステレオカメラ、広角カメラ、マイクアレイ等が挙げられる。本研究では、自律移動 (ナビゲーション) のみを対象とし、アーム機構は用いない。また、視点画像として RGB-D センサ (Xtion PRO LIVE) から得られるカラー画像および深度画像を用いる。




図 1: 知識転移概要図

2.3 actor と環境モデルの定義

本論文では、シミュレーション上で歩行者（人）を模した人型エージェントを actor と呼ぶ。actor は屋内環境内を移動する歩行者役として振る舞い、本研究では「すれ違い場面において主観的に違和感の少ない挙動」を生成できるかを評価する対象として位置づける（評価方法の詳細は第 7 章に示す）。

actor の移動には、シナリオごとに与える waypoint 列（目的地へ向かう参照点列）を用いる。既存手法として用いる Social Force Model (SFM) では、waypoint 列は参照目標（目的地）として与えられ、周囲の障害物に対する回避項を含む力学モデルにより速度・向きを計算して移動を生成する。一方、画像認識モデルに基づく actor では、視点画像に基づいて waypoint 列を補正し、得られた補正後 waypoint 列を追従することで移動を生成する（詳細は第 5 章）。なお、本研究で扱う「経路補正」の枠組みでは、補正前経路として waypoint 列を単純に結んだ参照経路を用い、SFM は参照経路の生成そのものには関与しない。

また、家庭環境シミュレータ上では、壁や家具等の静的障害物を含む屋内環境モデルを構築し、ロボットモデルと actor が同一の環境内で相互作用できるようにする（図 4）。

2.4 シミュレーション環境と実機環境の対応

本研究では、開発・学習・データ収集・検証のためにシミュレーション環境を用いるとともに、ロボットの比較評価は HSR 実機環境で実施する。シミュレーション環境は、(i) actor の評価実験、

表 1: 計算機・ソフトウェア環境（シミュレーション／実機）

	シミュレーション用 (デスクトップ PC)	実機用 (ノート PC)
OS	Ubuntu 24.04	Ubuntu 20.04
ROS	ROS Noetic (Docker 上で実行)	ROS Noetic
GPU	NVIDIA GeForce RTX 4060 Ti	NVIDIA GeForce RTX 4060
GPU Driver	570.195.03	580.82.09
CUDA	12.8	13.0
接続	—	ロボット本体と有線 LAN で接続
主用途	開発, 学習, シミュレーション実験, 推論評価	実機実験
共通事項	実機およびシミュレーションのいずれにおいても, 同一の ROS パッケージを用いてロボット制御および推論を行う.	

(ii) 学習用データセット収集, (iii) アルゴリズム実装と動作検証, (iv) 学習（モデル訓練）に用いる．実機環境は，ロボットナビゲーションの比較評価（主観評価および客観指標）に用いる．

表 1 に，シミュレーション環境と実機環境の計算機・ソフトウェア構成を示す．




図 2: システム概要図



図 3: TOYOTA の生活支援ロボット HSR (Human Support Robot)




図 4: ロボットと動的障害物の役割対応 (実環境／シミュレーション)

3 LLM に基づく行動生成手法

本章では、第2章で述べた経路補正の枠組みにおいて、LLM を用いて教師信号を生成する手法を述べる。具体的には、actor / ロボットの視点情報に基づき、安全な通行を満たす補正後経路（座標列）をオフラインで生成し、学習用データセットを構築する。

3.1 教師信号生成における LLM 利用の位置づけ

本研究における LLM の利用目的は、actor およびロボットの双方に対する「経路補正」の教師信号をオフラインで生成し、学習用データセットを構築することにある。従来の数値モデルやルールベース設計では、視点画像に含まれる局所的な環境状況（床上の通行可能領域や周辺障害物の配置など）と経路制約を統合しながら多様な補正例を設計することは容易ではない。そこで本研究では、視覚情報と補助情報を入力として与え、安全な通行を満たす補正後経路を座標列として生成できる点に着目し、LLM を教師データ生成に用いる。なお、LLM は応答時間の制約からシステム実行中には用いず、生成した教師信号を用いて学習した画像認識モデルを実行時に用いる。具体的な入力形式と出力形式は、それぞれ以降の「第3.2節 入力情報の設計」および「第3.4節 出力形式の設計」で述べる。

3.2 入力情報の設計

本研究では、LLM に対して actor / ロボットそれぞれの視点で得られる観測情報と、補正対象となる「補正前経路」を入力として与える。入力の基本構成は以下の通りである。

- カラー画像：actor / ロボットの視点で取得した RGB 画像
- 床領域マスク：Depth 画像とカメラ姿勢から生成した床上の通行可能領域マスク（LLM への補助入力）
- 補正前経路の点列：補正前経路をカメラ画像座標系で表した 2 次元点列（0-999 に正規化した $[y, x]$ の列）

床領域マスクは actor、ロボットの両方について LLM 入力として併用し、床上の通行可能領域を考慮しやすくする。一方で、床領域マスクは画像認識モデルの入力には用いず、LLM による教師データ生成時の補助情報としてのみ扱う。また、LLM には画像情報（カラー画像、床領域マスク）に加えて、補正前経路の点列をプロンプト内にテキストとして含める。点列は、補正前経路として与える元の waypoint 列（ピクセル座標）を画像サイズで正規化し、0-999 の整数に変換したうえで与える。補正前経路は「厳密に追従すべき軌道」ではなく、進行方向と目的地を表す参照情報として扱い、LLM は視点画像と床領域に基づいて安全な補正後経路へ修正する。なお、本研究では画像サイズやカメラ内部パラメータ、障害物の個別情報（物体マスク等）を LLM に明示的には与えず、画像と床領域マスクおよび点列から経路を生成させる。

床領域マスクは、カメラ姿勢と Depth 画像を用いて床面近傍に対応する画素を抽出することで生成する。床面近傍の判定は高さ許容範囲を $\pm 5\text{cm}$ として行う。本研究で用いるシミュレーション環境は段差や大きな傾斜（坂）が存在しない屋内環境を前提としており、この前提の下では高さに基づく床面近傍判定により通行可能領域を安定に抽出できる。

入力例として、LLM に与える視点カラー画像と床領域マスクの例を図5に示す。




図 5: LLM への入力例（左：視点カラー画像，右：床領域マスク；点列はプロンプト内のテキストとして付与）

3.3 プロンプト設計（教師信号生成の指示）

本研究では，Gemini 2.5 Pro を用い，視点カラー画像と床領域マスクを画像として入力し，補正前経路の点列をテキストとして追加入力するマルチモーダル推論により，補正後経路を生成する．プロンプトでは，経路生成の目的（安全な通行）と出力 JSON の形式を明示するとともに，入力として与える各情報（視点画像・床領域マスク・補正前経路点列）の役割を切り分けて指示する．特に，床領域マスク上に waypoint を配置することを必須条件として与え，通行可能領域からの逸脱を抑制する．なお，本研究で用いたプロンプトの全文は付録 A に示す．本文ではプロンプトの設計意図（入力情報，制約条件，出力形式）に焦点を当てて述べる．

補正前経路の点列は「経路生成のガイド（参照）」として扱い，入力点列どおりの形状を厳密に再現することや，先頭点へ厳密に一致させることは求めない．一方で，入力点列が示す「目的地のおおよその方向・位置関係」は尊重し，視野内で合理的に到達可能な範囲で終点（目的地）へ向かう傾向を保つよう指示する．これは，視点画像が移動中に取得される 1 フレームであり，実際の移動開始位置は画像外（下方）に存在するためである．また，本研究では「現在位置」が画像上のどの点に対応するか（例えば足元位置の画素）を LLM に明示的には与えていないため，入力点列の先頭点を厳密な始点として拘束すると不自然な生成を誘発する可能性がある．そのため，出力経路の始点（ $v = 999$ ）は画面中心に置く必要はなく，周囲状況に応じて回避済みの位置から開始してよい，という解釈を与える．

また，障害物回避に関しては，壁・柱等の静的障害物に加え，ロボットや人を動的障害物として扱い，将来の動きも想定して「近傍を通過しない」という保守的な方針を指示する．さらに，生成を複数のステップに分解し，各ステップで注意事項（例：床領域外の禁止，障害物近傍の回避，軌道の連続性）を明示することで，単発の指示よりも制約の解釈が安定するよう設計した．具体的には，生成過程を 1. 環境理解，2. 参照経路解析，3. 物体・障害物認識，4. 安全経路計画，5. 検証，6. 出力の 6 ステップに分解した．生成後には，すべての waypoint が床領域上にあり，障害物に近接せず，滑らかな連続軌道になっていることを検証し，満たさない場合は再生成する手順を含める．

3.4 出力形式の設計

本研究では、LLM の出力を「カメラ画像座標系における補正後経路の 2 次元点列」として定義する。具体的には、画像平面上の点列を 0-999 に正規化した座標で表現し、JSON 配列として出力させる。

座標はプロンプト中に与える補正前経路と同様に (u, v) (画像座標) で扱うが、出力では画像サイズに依存しないよう、画像の幅・高さで正規化して 0-999 の整数として表現する。本研究で用いる JSON の形式例を以下に示す。

```
[
  {"point": [999, 518], "label": "0"},
  {"point": [800, 540], "label": "1"},
  {"point": [600, 580], "label": "2"},
  {"point": [480, 550], "label": "3"},
  {"point": [420, 512], "label": "4"}
]
```

ここで、各要素は 1 つの waypoint を表し、point は $[v, u]$ (y 方向, x 方向) の順で格納する。label は先頭からの通し番号を文字列として付与する。

また、本研究の教師信号生成では、以下を出力の制約 (契約) として課す。

- 始点：出力の最初の waypoint (label="0") は、画像下端の $v = 999$ に置く。
- 終点：出力の最終 waypoint は、補正前経路の最終点 (目的地) に一致させる。
- 床制約：すべての waypoint は床領域マスク (緑領域) 上になければならない。もし床外に出る場合は、最も近い床領域上の点へ移動させる。また、目的地が床外の場合も同様に最近傍の床領域上の点を終点とする。

LLM が JSON として解釈できない出力を返した場合は、出力形式を満たすまで再生成 (再試行) を行い、教師データの品質を担保する。

出力例として、LLM が生成した補正後経路 (JSON の点列) を画像上に描画した例を図 6 に示す。

3.5 actor に対する教師信号生成

actor に対しては、シミュレーション上で取得できる actor 視点の観測 (カラー画像, 床領域マスク) と補正前経路 (点列) を入力として与え、通行可能領域を踏まえた補正後経路 (座標列) を LLM に生成させる。補正前経路には、シナリオごとにあらかじめ与える waypoint 列 (目的地へ向かう参照経路) を用い、カメラ視野内に対応する区間のみを抽出して点列として与える。ここで得られた補正後経路は、actor を制御する画像認識モデルの教師信号として用いる (学習は第 4 章)。

3.6 ロボットに対する教師信号生成

ロボットに対しても actor と同様に、ロボット視点の観測 (カラー画像, 床領域マスク) と補正前経路 (点列) を入力として与え、補正後経路 (座標列) を LLM に生成させる。補正前経路




図 6: LLM が生成した補正後経路の可視化例（緑線：補正前経路，赤点：補正後経路の waypoint とラベル；本図は可視化のための描画であり，学習入力に用いる「補正前経路画像」とは異なる）

には，ROS（Robot Operating System）における標準的なナビゲーションスタックの構成要素である move_base が出力するグローバルパスの直近区間を，カメラ座標系に投影した点列を用いる．move_base は，グローバル／ローカルプランナとコストマップに基づき目標姿勢への移動を実行する枠組みを提供し，移動ロボットの自律走行に広く用いられている [20][21][22]．得られた補正後経路は，ロボットの経路補正用画像認識モデルの教師信号として用いる（学習は第 4 章）．

4 画像認識モデルの学習

本章では、第3章で示した LLM による教師信号生成の枠組みに基づき、生成した教師データを用いて軽量な画像認識モデルを学習する手順を述べる。本研究では、システム実行時のリアルタイム性を確保するため、LLM をオンラインで呼び出すのではなく、LLM が生成した補正後経路を教師ラベルとして用い、画像認識モデルによる教師あり学習として知識を移す。

4.1 学習の位置づけ

LLM による教師信号生成は多様な補正例を作れるが、推論コストや応答時間の観点から、実行時に直接利用することには制約がある。そこで、LLM が生成した補正後経路（座標列）を教師ラベルとして用い、カラー画像と補正前経路画像を入力とし、補正後経路を出力する画像認識モデルを学習する。画像認識モデルは LLM を用いる場合と比べて実行時に高速に推論できるため、動的障害物や未知障害物の存在を考慮した局所的な経路修正に利用できる。この枠組みにより、実行時には LLM を直接呼び出す必要がなく、推論処理を一定の計算コストで安定して実行できる。また、教師データ生成（LLM）と実行時処理（モデル推論）を分離できるため、教師信号生成をオフラインで集中的に行い、得られたデータを用いてモデルを段階的に改善する運用が可能となる。一方で、画像認識モデルが LLM の生成結果（教師信号）をどの程度再現できるかは、教師信号の品質やデータ分布に強く依存するため、生成データの検証や不適切な例の除外が重要となる。しかし本研究では、LLM 出力の経路を大規模に収集し、その統計的傾向を学習モデルへ転写することを主目的とするため、教師信号の品質チェックは体系的には実施せず、LLM の出力をそのまま蒸留に用いた。なお、LLM には waypoint が床領域マスク上にあることを満たすよう指示し（第3.3節参照）、逸脱の抑制を意図した最小限の制約は付与している。この設計により、教師信号に起因する誤差が学習結果に混入する可能性がある点は、本手法の制約として考察で述べる。

4.2 学習データセットの構成

学習データは、actor／ロボットそれぞれの視点で収集した入力と、LLM が生成した補正後経路から構成される。本研究では actor 用とロボット用で視点（カメラ位置）や運動条件が異なるため、データセット作成と学習は別々に実施し、それぞれに適合した学習済み重みを得る。

各サンプルは、視点カラー画像（RGB）1枚と、補正前経路を画像平面へ描画した入力パスマスク、および LLM が生成した補正後経路（座標列）から構成される。

データは training data と validation data に 8:2 で分割し、validation data を各エポックの損失計算に用いる。左右反転による拡張を含む分割後のデータ数は、actor 用が training data 4120 枚、validation data 1032 枚、ロボット用が training data 2704 枚、validation data 676 枚である。

学習環境は2種類用意した。1つは研究室周辺（本学 F2 棟 2 階と 本学 F1 棟 2 階の一部）を再現した環境であり、実環境の構造を想定したデータを収集する。もう1つは壁や扉等を配置した簡易環境であり、部屋・通路・直線・曲がり角等を含む多様な構造を含める。

actor 視点では、複数の actor を用意し、それぞれに視点カメラを搭載して視点・障害物の両方の役割を持たせる。また、ダミーのロボットモデルを障害物として通路や部屋に複数配置する。ロボット視点では、視点となるロボットは1台とし、actor を複数人配置して障害物として扱う。ロボットは環境に1台を想定するため、障害物としてのロボットは用いない。

4.3 モデル入出力と教師表現

画像認識モデルの入力は、視点カラー画像（ 144×144 , 3 チャンネル）と、補正前経路を画像平面へ描画した入力パスマスク（ 144×144 , 1 チャンネル）である。両者をチャンネル方向に結合し、4 チャンネル画像としてネットワークへ入力する。出力は、補正後経路を表す出力パスマスクに対応する「各行の通過列」を推定する。本研究では、経路が画像下方（手前）から上方（奥）へ単調に伸びると仮定し、各行（ y ）には通過すべき点が高々 1 点のみ存在するものとしてモデル化する。具体的には、各行に対して $x \in \{0, \dots, 143\}$ の 144 クラス分類を行い、さらに「その行ではパスが存在しない」場合を表す 1 クラスを追加して、合計 145 クラス分類として扱う。

教師信号として得られる補正後経路（座標列）は、学習可能な画像表現へ変換する必要がある。本研究では、座標列を画像平面へ投影し、連続する点間を直線で結ぶことでパスを 1 画素幅の線として描画し、二値マスク（0/1）を教師として用いる。

また、145 クラス分類の教師ラベルは、上記マスクから各行ごとに「正解（教師）点が存在する列」を抽出して構成し、教師点が存在しない行は「パスなし」クラスを割り当てる。

実装上は、座標列を元画像サイズから 144×144 ヘスケーリングしたのち、折り返し（ y が増加し始める）を検出した時点で後続点を打ち切り、不自然なループを含まない単方向の軌道としてマスク化する。

4.4 学習手順と損失関数

学習は、入力（RGB + 入力パスマスク）から出力（出力パスマスク）を推定する教師あり学習としてモデル化する。ネットワークは encoder-decoder 型の畳み込みニューラルネットワークであり、エンコーダ側でダウンスケールしながら特徴抽出を行い、デコーダ側で転置畳み込みにより元解像度へ復元して出力パスマスクを生成する。ネットワーク構造の概略を図 7 に示す。図は左から右へ処理が進み、入力は視点カラー画像（RGB）と入力パスマスクをチャンネル方向に結合した 4 チャンネル画像である。図中のボックスは各層での特徴マップを表す。それぞれ、畳み込み + Batch Normalization + ReLU（黄 + オレンジ）、転置畳み込み + ReLU（青 + オレンジ）、最大プーリング（赤）、および最終段の Softmax 処理（紫）を表す。また、各ブロック下に示す数値は、各段における特徴マップのチャンネル数と空間解像度（縦横サイズ）を表しており、エンコーダ側ではプーリングにより解像度を段階的に縮小しつつ特徴を抽出し、デコーダ側で転置畳み込みにより元の解像度へ復元する。

損失関数は Softmax Cross Entropy を用いる。具体的には、入力画像 I と入力パスマスク M を画像認識ネットワーク $Net(I, M)$ に与えて得られる出力 Z に対し、行 y ごとに Softmax を適用して出力 Y を算出し、教師ラベル L とのクロスエントロピーを計算する。以下にその定義を示す。

$$\begin{aligned}
 Z &= Net(I, M) \\
 Y &= SoftMax(Z) \\
 Y(x, y) &= \frac{\exp(Z(x, y))}{\sum_{x'=0}^N \exp(Z(x', y))} \\
 l &= CrossEntropy(Y, L) \\
 &= -\frac{1}{N(N+1)} \sum_{x=0}^N \sum_{y=0}^{N-1} L(x, y) \log(Y(x, y))
 \end{aligned}$$




図 7: 画像認識モデルのネットワーク構造 (encoder-decoder)．入力 (RGB + 入力パスマスク, 計 4 チャンネル) から, 各行に対する 145 クラスの分類結果を出力する．

ここで $Z(x, y)$ は行 y におけるクラス x の出力, $Y(x, y)$ はその確率を表す. $L(x, y)$ は教師ラベルであり, 損失 ℓ は全画素 (全行・全列) で平均したクロスエントロピーである.

各行の分類タスクとして扱うため, 教師も各行ごとに { 通過列, またはパスなし } を持つラベルとして構成する. 最適化手法には Adam[23] を用い, 学習率は 1×10^{-3} , ミニバッチサイズは 64, 学習エポック数は 40 とする. 各エポックの終わりに評価用データで損失を算出し, 学習の進行を確認する.

4.5 推論時の後処理と waypoint 生成

4.5.1 後処理なし (単純復元)

推論では, 各行の分類結果 (Softmax 出力) から経路点列を復元する. 具体的には, 各行について最大値のクラスを選択し, 以下の規則で点列を構成する.

- (1) 選択クラスが パスなしの場合は, その行の点は出力しない.
- (2) 選択クラスが パスなし以外の場合は, x 座標として採用する.

この処理により, 「各行につき高々 1 点」の点列を得られ, 以降の制御・座標変換処理へ接続しやすい表現となる. また, 低信頼な推定を抑制するため, 後処理なし (単純復元) の条件においても, 最大値が所定のしきい値未満の場合は「パスなし」と同様にその行を欠損として扱う. ただし, 後処理なしでは点列がジグザグに揺れたり, 欠損が断続的に生じたりする場合がある. そこで, 行方向の連続性を明示的に考慮した後処理 (行方向平滑化) を導入する.

4.5.2 後処理あり (行方向平滑化)

後処理として, 点列のジグザグや欠損の断続を抑えるため, 行方向の平滑化後処理を適用する. 画像認識モデルの出力 Y を行 c ごとにクラス $s_r \in \{0, 1, \dots, N-1, N\}$ の $N+1$ クラスの尤度 $p(c, s_r)$



図 8: 教師経路と推定経路, および後処理の有無による推定結果の差を可視化した例. 左から順に, 入力画像, 入力経路画像, 教師経路画像, 後処理なし (単純復元) の推定経路画像, 後処理あり (行方向平滑化) の推定経路画像を示し, 入力画像以外は同一の入力画像上に重畳表示した.

とみなし, これを用いて最尤となる系列 $\mathbf{s} = (s_c)_{c=0}^{N-1}$ を求める. まず, 各行ごとのスコアおよび遷移ペナルティを以下の通りに定義する:

$$\phi_c(r) = \log(p(c, s_r)) \quad (1)$$

$$\psi(i, j) = \begin{cases} 0 & i = j \\ \lambda_{col}|i - j| & i \neq j, (i \neq N, j \neq N) \\ \lambda_{switch} & otherwise \end{cases} \quad (2)$$

ここで λ_{col} は行間の状態遷移に対する罰則, λ_{switch} はパスありからパスなし, もしくは, その逆の状態遷移に対する罰則である. 前者により行方向の連続性を促し, 後者により欠損の頻繁な出現や不必要な断続を抑える. これに基づき, 隣接行間のクラス遷移を考慮したクラス列は

$$\hat{\mathbf{s}} = \arg \max_{\mathbf{s}} \left(\sum_{c=0}^{N-1} \phi_c(s_c) + \sum_{c=0}^{N-2} \psi(s_c, s_{c+1}) \right) \quad (3)$$

で与えられる. 本問題は一次元鎖の事後確率最大化推定問題であり, Viterbi アルゴリズムで効率的に解くことができる. 得られた $\hat{\mathbf{s}}$ に基づき, 前節と同様の規則で点列を復元することで, 滑らかで連続性の高い waypoint 列を得る. また, 後処理なしおよび後処理ありによる経路復元結果の差を可視化するため, 入力画像, 入力経路画像, 教師経路画像, 後処理なしの推定経路画像, 後処理ありの推定経路画像を図 8 に示す. 図より, 後処理なしの推定経路では経路の欠損が断続的に生じているのに対し, 後処理ありの推定経路ではこれらの欠損が補間・平滑化され, より連続的な経路に改善していることがわかる.

4.5.3 実空間座標系への変換

復元した waypoint 列は画像座標系で与えられるため, ロボットの制御に用いるには実空間座標系へ変換する必要がある. 本研究では, 屋内の平坦な床面を前提とし, カメラの内部パラメータおよびカメラとロボット間の外部パラメータに基づいて, 各 waypoint を床面上へ射影する. 得られた点をロボット座標系に変換し, ロボット座標系上の waypoint 列を追従制御の入力として用いる.

4.6 評価指標 (モデルの評価)

本研究では, LLM が生成した経路 (参照経路) を教師信号として学習した画像認識モデルを実行時に用いる. したがって, 画像認識モデルが参照経路をどの程度再現できるか, および実行時

運用に耐える計算量であるかを評価する必要がある。評価は第 7 章において、actor 用／robot 用データセットそれぞれに対し、後処理（行方向平滑化）の有無も含めて実施する。

具体的な評価観点は以下のとおりである。

- 出力率（有効行率）：参照点が存在する行に対し、予測点が得られた行の割合。
- 再現誤差：参照列 $x_{GT}(y)$ と推定列 $x_{pred}(y)$ の列方向誤差 $|x_{pred} - x_{GT}|$ (px) の統計量。
- 許容誤差内率：許容誤差 τ 以内に収まる割合（欠損を含む場合も併記）。
- 平滑性：推定列系列の 1 次差分・2 次差分に基づく滑らかさ。
- リアルタイム性：画像認識モデルの 1 回推論時間と、LLM API 応答時間（end-to-end）。

評価手順，条件，集計方法の詳細と結果は第 7 章に示す。

5 actor の行動生成

本章では、ロボット評価に用いる歩行者役エージェント (actor) の行動生成方法について述べる。人と共生する移動ロボットの研究において、ロボットが人とすれ違う状況を含む評価を行うためには、人の存在を想定した評価環境を構築できることが重要である。この観点から、ロボット評価に用いる「人らしく振る舞う actor」を構築することは、一般的に有用な課題として位置づけられる。

ただし、本研究における「人らしさ」は、人間の歩行挙動を行動科学的・統計的に厳密再現することを意味しない。本研究では、人やロボットとすれ違う際に、人が主観的に違和感や不自然さを覚えない挙動であるかどうかを、人らしさの指標として用いる。すなわち、主観評価に基づく印象を用いて、actor の行動生成手法の妥当性を評価する。主観評価の方法および実験条件の詳細は第 7 章に示す。

本章では、actor の行動生成手法として以下の 2 種類を定義する。

1. 比較対象として用いる Social Force Model (SFM) に基づく actor
2. 画像認識モデルを用いて経路補正を行う actor

これらは、いずれもシミュレーション環境において動的障害物として振る舞い、すれ違い状況を構成するために用いる。

5.1 actor の役割と設計方針

actor は、シミュレーション環境上で歩行者 (人) を模擬する動的障害物として移動する。actor の役割は、ロボットが人とすれ違う状況を含む環境条件を構成し、評価可能な形で再現することである。本研究では、ロボット評価に用いる actor を構築することを目的とするが、同時に、actor の行動生成が主観的に人らしいと受け取られる挙動を生成できるかという観点から、actor 行動生成手法自体の妥当性も検討対象とする。

設計方針として、異なる行動生成手法を比較できるよう、入出力の整理を行い、シミュレーション上で安定して動作することを重視する。

5.2 actor の入出力と制御ループの概要

本研究における actor の行動生成は、「(1) 外界情報の取得」、「(2) 行動生成」、「(3) 移動実行」の流れで構成される。ここで行動生成とは、次時刻以降の移動のための指令 (移動方向・速度、あるいは追従すべき経路) を生成する処理を指す。

SFM に基づく actor と画像認識モデルに基づく actor では、waypoint の役割と移動生成の過程が異なる。SFM actor では、waypoint は目的地または参照点として与えられ、SFM に基づく力計算を介して移動方向と速度が決定される。一方、画像認識モデル actor では、入力された waypoint 列を画像認識モデルにより補正し、補正後 waypoint 列を生成した上で、それを追従することで移動を行う。以降、それぞれの actor の行動生成方法を述べる。

5.3 比較対象 1：SFM に基づく actor

Social Force Model (SFM) は、歩行者を質点として扱い、目的地へ向かう駆動力と、他者・障害物からの回避力などの合成により歩行者の運動を記述するモデルである。本研究では、既存の歩行者モデルに基づく比較対象として SFM に基づく actor（以下、SFM actor）を用いる。

SFM actor において、waypoint は目的地または参照点として事前に与えられる。この waypoint 自体は障害物等を考慮したものではなく、周囲の障害物や通行可能領域に関する情報は含まれていない。SFM actor は、Gazebo から取得した周辺障害物情報を用いて SFM に基づく力計算を行い、得られた移動方向および速度に従って移動する。また、SFM actor は視覚センサを持たず、カメラ画像などの視覚情報は用いない。

以上より、SFM actor は、周辺障害物情報に基づく力学モデルによって反応的に移動を生成する手法として位置づけられる。

5.4 比較対象 2：画像認識モデルによる経路補正 actor

本研究では、第 4 章で学習した画像認識モデルを用いて、視覚情報に基づく経路補正を行う actor（以下、画像認識モデル actor）を定義する。

画像認識モデル actor は、actor 視点のカラー画像と、補正前の waypoint 経路を画像平面上に描画した入力パスマスクを入力として受け取り、補正後の経路を推論する。推論結果は後処理を経て補正後 waypoint 列へ変換され、actor はこの補正後 waypoint 列を追従することで移動する。後処理および waypoint 生成の詳細は第 4.5 節に示す。

画像認識モデル actor における推論は、一定時間間隔で実行される。本研究の実験では、0.1 秒ごとに推論を行った。推論が行われない制御周期においては、直近に生成された補正後 waypoint 列を追従する。この構成により、視覚情報に基づく経路補正を行いつつ、推論回数を抑えて計算負荷を調整する。

なお、画像認識モデル actor は SFM に基づく力計算を用いず、画像認識モデルによって補正した waypoint 列を直接追従する点が、SFM actor と異なる。

5.5 実装（シミュレーション内での actor 制御）

シミュレーション実行時には、actor の状態更新周期、視点画像の取得周期、および推論周期の関係を考慮し、安定した移動を実現する必要がある。

SFM actor では、Gazebo から取得した周辺障害物情報に基づいて SFM による力計算を行い、得られた移動方向および速度に従って actor を移動させる。一方、画像認識モデル actor では、推論により生成された補正後 waypoint 列を追従することで actor を移動させる。

画像認識モデル actor では、推論結果から得られる waypoint 列が欠損または不連続となる場合があるため、追従の安定化を目的として平滑化や補間処理を適用する。これにより、不自然な急激な方向変化や振動を抑制し、評価に適した安定した挙動を得る。

5.6 評価の位置づけ

本章で定義した actor は、ロボット評価において人の存在を想定した環境条件を構成するための要素である。本研究では、actor の挙動がすれ違い状況において人の主観に基づく印象とどの程度

整合しているかを確認することで、ロボット評価に用いる「人らしく振る舞う actor」が構築できているかを検証する。actor の主観評価の方法（アンケート設計，実験条件，解析方法など）の詳細は第 7 章に示す。

6 ロボットの行動生成（ナビゲーション）

本章では、実機ロボットにおけるナビゲーション（行動生成）の設計を述べる。ロボットは目標地点へ到達する行動主体であり、移動中に障害物を回避しながら安全に走行することが求められる。本研究では、ロボットの行動生成手法として以下の2種類を定義する。

1. 比較対象として用いる `move_base` に基づくナビゲーション
2. 画像認識モデルを用いて局所的に経路補正を行うナビゲーション

画像認識モデルは、第4章で述べた枠組みにより学習されたものであり、実行時には LLM を直接用いずに推論を行う。

6.1 ロボットの役割と設計方針

ロボットの役割は、目標地点へ自律移動し、周囲状況に応じて安全に走行することである。本研究では、比較対象として `move_base` による走行を用いる。

一方、動的障害物や未知障害物が存在する状況では、視野内の局所状況に応じた回避が必要になる場合がある。そこで本研究では、`move_base` が生成する経路を基準としつつ、ロボット視点の観測に基づき局所的な経路補正を行う構成を導入する。

なお、本研究におけるロボットの「安全な走行」は、衝突回避等の物理的安全性が確保されていることを前提に、対人場面において人に不安や怖さを与えないといった心理的安全性に着目して扱う。また、対人回避においては、移動時間の増加や減速・停止が生じる場合があっても、人に配慮した動きとなっているか、およびその動きが予測可能であるかを重視する。これらは、第7章に示すアンケート項目（安全性と効率、配慮と主体性、予測可能性と機敏さ）によって評価する。一方、第5章の actor は、人がすれ違い時に感じる印象に基づき、人らしく振る舞う動的障害物としての妥当性を検討対象とした点が異なる。

6.2 ロボットの入出力と制御ループの概要

本研究におけるロボットの行動生成は、「(1) 経路の取得（計画）」、「(2) 局所経路の決定」、「(3) 速度指令 (`cmd_vel`) の生成と移動実行」の流れで構成される。

`move_base` に基づく走行では、経路計画から局所計画、速度指令生成までを `move_base` が担い、ロボットは `move_base` の出力に従って移動する。一方、画像認識モデルによる補正を行う走行では、`move_base` が生成するグローバルパスのうちロボット視点の視野内に投影できた点のみを「補正前経路」として取り出し、ロボット視点のカラー画像と補正前経路画像（入力パスマスク）を入力として補正後経路を推論する。推論結果は後処理により補正後 waypoint 列へ変換され、その waypoint 列を追従することで移動する（後処理および waypoint 生成は第4.5節に従う）。以降、それぞれのロボットの行動生成手法を述べる。

6.3 比較対象 1：`move_base` に基づくナビゲーション

比較対象として、ROS の `move_base` により自律移動を行う。本研究の比較対象では、経路計画から局所計画、速度指令 (`cmd_vel`) の生成までを `move_base` が一括して担い、本研究側で移動の操作や介入は行わない。

6.4 比較対象 2：画像認識モデルによる局所経路補正ナビゲーション

本研究では、第 4 章で学習した画像認識モデルを用いて、視覚情報に基づく局所経路補正を行うナビゲーションを定義する。

画像認識モデルの入力は、ロボット視点のカラー画像と、補正前経路を画像平面上に描画した入力パスマスクである。ここで補正前経路は、`move_base` が生成するグローバルパスのうち視野内に投影できた点のみから構成する。モデルはこれらを用いて補正後経路を推論し、後処理により補正後の waypoint 列を生成する（詳細は第 4.5 節）。

画像認識モデルによる推論は一定時間間隔で実行される。本研究では 0.1 秒ごとに推論を行う。推論が行われない制御周期においては、直近に生成された補正後 waypoint 列を追従する。

6.5 実装（実機内でのロボット制御）

画像認識モデルによる補正を行う走行では、`move_base` のグローバルパスを基準として取得し、補正前経路（視野内に投影できた点のみ）を入力として画像認識モデルで補正後 waypoint 列を生成する。ロボットはこの補正後 waypoint 列を追従することで移動する。

補正後 waypoint 列の追従には自作追従器を用いる。追従器では、最高速度・角速度・加速度・角加速度などをパラメータとして指定し、経路を追従するように速度指令 (`cmd_vel`) を生成する。また、走行中の頭部カメラは、経路上の指定距離先を見つめるように制御する。

6.6 評価の位置づけ

本章で定義したロボットの行動生成手法は、第 7 章において実機ロボットによる評価を行う。具体的には、`move_base` に基づく走行と、画像認識モデルによる局所経路補正を導入した走行を比較し、経路長・所要時間などの数値指標およびアンケート評価により検討する。評価手順・条件・指標の詳細は第 7 章に示す。

7 実験および評価

7.1 実験設定

7.1.1 評価の目的と位置づけ

本章では、提案手法を多面的に評価するため、(i) 画像認識モデルの性能、(ii) リアルタイム性（推論時間）、(iii) actor 挙動に対する主観評価、(iv) ロボット挙動に対する主観評価、(v) 実機実験における定量評価（所要時間・移動距離）の順に結果を示す。

7.1.2 被験者

被験者は研究室の学生 7 名である。主観評価を伴う実験では、被験者はすれ違い場面における「歩行者（すれ違う人）」の役割を担い、各試行後にアンケートへ回答した。

7.1.3 条件設計と試行数

シミュレーション実験では、相手 actor の挙動生成手法として Social Force Model (SFM) を用いる条件と画像認識モデルを用いる条件の 2 条件を設定した。各被験者は各条件を 1 回ずつ実施し、合計 14 試行（7 名 × 2 条件）を行った。

実機実験では、ロボットのナビゲーション手法として move_base を用いる条件と画像認識モデルを用いる条件の 2 条件を設定した。各被験者は各条件を 1 回ずつ実施し、合計 14 試行（7 名 × 2 条件）を行った。

7.1.4 評価指標

画像認識モデルの性能評価（第 7.2 節参照）では、LLM を教師として構築した蒸留モデルが、教師（LLM）の出力をどの程度再現できているかを検証する。リアルタイム性評価（第 7.3 節参照）では、LLM と画像認識モデルの推論時間を比較し、計算コストの観点から実運用可能性を検討する。主観評価（第 7.4 節、第 7.5 節参照）では、設問 Q1-Q6 に基づき、すれ違い挙動に対する印象を評価する。実機実験における定量評価（第 7.6 節参照）では、所要時間および移動距離を計測し、条件間で比較する。

7.1.5 アンケート設計

アンケートは 5 段階リッカート尺度を用い、5 を「非常にそう思う」、4 を「ややそう思う」、3 を「どちらともいえない」、2 を「あまりそう思わない」、1 を「全くそう思わない」とした。設問は「安全性 vs 効率」「配慮 vs 主体性」「予測可能 vs 機敏さ」のトレードオフを意図して構成した。Q1 は評価対象に応じて文言を切り替え（actor 版／ロボット版）、Q2-Q6 は共通の設問文を用いた。また、結果の可視化においては、否定的内容を含む設問（Q2, Q4, Q6）を反転し、すべての項目で高い値が望ましい評価を示すように正規化した。

7.1.6 本章の構成

以降、第 7.2 節で画像認識モデル自体の性能を確認し、第 7.3 節で推論時間の比較結果を示す。続いて、第 7.4 節および 第 7.5 節により主観評価を報告し、最後に第 7.6 節において所要時間と移動距離を用いた定量比較を行う。

7.2 画像認識モデルの性能評価

本節では、大規模言語モデル (LLM) が生成した経路を、学習済み画像認識モデルがどの程度再現できているかを定量的に評価する。評価は actor 用データセットおよび robot 用データセットそれぞれに対して実施し、推論出力をそのまま用いる場合 (後処理なし) と、行方向の平滑化後処理を適用した場合 (後処理あり) を比較する。これにより、推論時に LLM を用いず画像認識モデルのみで LLM 経路を追従できるか、および後処理が再現性と平滑性に与える影響を検証する。結果は、要約統計量を表として整理するとともに、誤差分布の形状を確認するため絶対誤差のヒストグラムを併せて示す。

7.2.1 実験方法

データセットは学習時に用いた train/val 分割 (8:2) を固定し、追加学習は行わず、val データを用いて評価した。各サンプルに対し、教師データとして LLM 経路に基づく各行の正解列 x_{GT} を与え、画像認識モデルの推定列 x_{pred} と比較した。

評価は以下の 4 観点から行った。

- **有効行率**：GT が存在する行数 (GT 行数) に対して、GT が存在し、かつ予測も得られた行数 (有効行数) の比 (有効行率) を算出した。
- **再現誤差**：有効行に対して絶対誤差 $|x_{pred} - x_{GT}|$ を計算し、平均誤差、標準偏差、p95、最大値を算出した。
- **許容誤差内率**：許容誤差 τ 以内に収まる割合 ($\tau = 2, 4, 6, 8, 10, 12$) を (i) 分母を有効行数とした場合 (有効行ベース) と、(ii) 分母を GT 行数とした場合 (欠け込みを含む) で算出した。
- **平滑性**：推定経路の滑らかさを評価するため、1 次差分 $|\Delta x|$ および 2 次差分 $|\Delta^2 x|$ の統計量 (平均、p95) を算出し、所定の閾値に基づく評価点数も併記した。

ここで、本節で扱う x は、 144×144 にリサイズした画像平面上の列インデックス ($x \in \{0, \dots, 143\}$) である。したがって、 $|x_{pred} - x_{GT}|$ は同解像度上での列方向誤差であり、単位は px (pixel) として報告する。

モデル出力は、各行 y に対する 145 クラス ($x = 0, \dots, 143$ と「パスなし」 $x = 144$) の確率分布 (Softmax 出力) である。後処理なしの条件では、この確率分布から行ごとに推定列 x_{pred} を復元した。基本は最大確率クラスを選択し、選択クラスが「パスなし」($x = 144$) の場合はその行の点を出力しない (欠損)。ただし本研究では、低信頼な推定を抑制するため、最大確率がしきい値 (0.1) 未満の場合も「パスなし」と同様に欠損として扱った。

表 2: LLM 経路に対する画像認識モデルの再現性能（基本・誤差）

モデル の種類	後処理 の有無	GT 行数	有効 行数	有効 行率	平均誤差 (px)	標準偏差 (px)	p95 (px)	最大 (px)
actor 用	有り	30628	30312	0.99	7.55	8.66	23	97
	無し	30628	30464	0.99	7.65	8.62	24	97
robot 用	有り	42187	41892	0.99	8.09	11.21	31	72
	無し	42187	41189	0.98	8.09	11.39	32	116

後処理ありの条件では、上記で得た推定列系列に対して Viterbi アルゴリズムによる行方向平滑化を適用した。これは隣接行間の連続性を考慮して経路を抽出し、必要に応じて欠損行（パスなし）の補間やギャップ抑制を行うものである。

また、誤差分布を可視化するため、絶対誤差 $e = |x_{\text{pred}} - x_{\text{GT}}|$ のヒストグラムを作成した。ヒストグラムは有効行のみを対象として度数を集計し、全度数で正規化した相対度数（割合）として表示した。欠損行（「パスなし」および最大確率がしきい値未満）はヒストグラムの集計対象外とし、有効行率として別途評価した。

なお、画像認識モデルの入出力定義、145 クラス化（パスなしクラスの追加）、および推論後処理の位置づけの詳細は第 4 章を参照されたい。

7.2.2 結果

actor 用データセットおよび robot 用データセットにおける評価結果を、表 2 から表 4 に示す。また、誤差分布の形状を比較するため、絶対誤差 $e = |x_{\text{pred}} - x_{\text{GT}}|$ の相対度数ヒストグラムを作成し、actor 用（図 9）および robot 用（図 10）として示す。

表 2 より、有効行率はいずれの条件でも高く、actor 用では 0.99、robot 用では 0.98–0.99 であった。再現誤差の平均は、actor 用で 7.55 px（後処理あり）/ 7.65 px（後処理なし）、robot 用で 8.09 px（後処理あり）/ 8.09 px（後処理なし）であり、平均値の観点では後処理の有無による大きな差は見られない。

表 3 より、許容誤差内率は τ の増加に伴い単調に上昇し、例えば $\tau = 12$ では actor 用で 0.80、robot 用で 0.77（有効行ベース）となった。一方で欠け込み（分母 = GT 行数）を含めた場合も同様の傾向を示し、有効行率と合わせて推定の安定性が確認できる。

平滑性指標の比較を表 4 に示す。後処理なしでは 1 次差分および 2 次差分の p95 が大きく、行方向に急な変動を含む系列が生成されているのに対し、後処理ありでは 1 次差分・2 次差分ともに GT 系列に近い値まで低減している。なお、図 9、図 10 のヒストグラムは有効行のみを対象として度数を集計し、全度数で正規化した相対度数（割合）として表示した。欠損行（「パスなし」および最大確率がしきい値未満）はヒストグラムの集計対象外とし、有効行率として別途評価している。

7.2.3 考察

表 2 より、有効行率はいずれの条件でも 0.98–0.99 と高く、画像認識モデルが大部分の行に対して推定結果を安定して出力できていることが確認できる。また、再現誤差の平均は actor 用で約 7.6 px、robot 用で約 8.1 px であり、蒸留元である LLM 経路（教師系列）に対して一定の再現性

表 3: LLM 経路に対する画像認識モデルの再現性能（許容誤差内率）

モデル の種類	後処理 の有無	許容誤差内率（有効行） 分母=有効行数						許容誤差内率（欠け込み） 分母= GT 行数					
		$\tau = 2$	$\tau = 4$	$\tau = 6$	$\tau = 8$	$\tau = 10$	$\tau = 12$	$\tau = 2$	$\tau = 4$	$\tau = 6$	$\tau = 8$	$\tau = 10$	$\tau = 12$
actor 用	有り	0.33	0.49	0.59	0.68	0.75	0.80	0.33	0.49	0.58	0.67	0.74	0.79
	無し	0.33	0.49	0.59	0.67	0.75	0.80	0.33	0.48	0.58	0.67	0.74	0.79
robot 用	有り	0.45	0.56	0.63	0.68	0.73	0.77	0.45	0.55	0.62	0.68	0.72	0.76
	無し	0.46	0.56	0.63	0.68	0.73	0.77	0.45	0.55	0.61	0.67	0.71	0.75

表 4: 平滑性指標の比較

データ セット	系列	1 次差分 $ \Delta x $		2 次差分 $ \Delta^2 x $	
		平均	p95	平均	p95
actor 用	GT	0.50	2	0.43	1
	モデル（後処理あり）	0.35	2	0.59	3
	モデル（後処理なし）	1.67	8	3.02	15
robot 用	GT	0.25	1	0.32	1
	モデル（後処理あり）	0.22	1	0.42	2
	モデル（後処理なし）	0.86	5	1.62	9

が得られている。これらの結果は、推論時に LLM を用いずとも画像認識モデルのみで LLM 経路を概ね追従できる可能性を示唆する。

誤差分布（図 9、図 10）では、いずれの条件でも小さい誤差領域に相対度数の山が形成されており、多くの行で x_{pred} が x_{GT} の近傍に推定されていることが分かる。一方、表 3 より、 $\tau = 6$ で約 6 割、 $\tau = 12$ で約 8 割（有効行ベース）の行が許容範囲に入っている。本研究の設定では、 $\tau = 6$ および $\tau = 12$ は距離スケールに換算するとそれぞれ約 0.3m、0.6m 程度に相当し、概ね人の半身から体幅に対応する範囲である。したがって、今回の目的（LLM 経路の追従を画像認識モデルで代替すること）に照らすと、一定の許容誤差内で教師経路を再現できている点は実用上の近似として妥当であると考えられる。

後処理の効果について、表 2 および図 9、図 10 から、平均誤差や誤差分布の外形は後処理の有無で大きく変化していない。すなわち、本研究で用いた Viterbi アルゴリズムによる行方向平滑化は、平均的な誤差を縮めるというよりも、系列の急変や不連続を抑制して経路形状を整える役割が支配的である。実際に、表 4 より、後処理なしでは 1 次差分 $|\Delta x|$ の p95 が actor 用で 8、robot 用で 5 と大きいのにに対し、後処理ありではそれぞれ 2、1 に低減している。同様に 2 次差分 $|\Delta^2 x|$ の p95 も、actor 用で 15 から 3、robot 用で 9 から 2 へと低減しており、後処理が誤差特性を大きく損なうことなく、経路を GT と同程度の滑らかさへ近づけていることが確認できる。このことから、後処理は「誤差を減らす」よりも、「誤差を保ったまま経路を平滑化する」処理として有効であるといえる。




図 9: 誤差分布の比較 (actor 用モデル)

actor 用と robot 用を比較すると、平均誤差は robot 用の方がわずかに大きい (約 8.1 px)。これは、入力画像の視点条件の違いにより通路幅や床領域の見え方が変化し、同じ物理的ずれでも画像平面上では相対的に大きい列方向誤差として現れた可能性がある。

本研究では LLM 出力を原則そのまま教師として用いたため、教師信号由来の不適切な経路が誤差として混入し得る。以下では、この影響も含めて誤差要因を分析する。平均誤差および最大誤差が大きいサンプルを抽出し、可視化した代表例を図 11 に示す。各画像では、入力画像上に LLM の出力経路 (GT; 赤)、入力経路 (青)、画像認識モデルの推定経路 (後処理なし; オレンジ)、および行方向平滑化後の推定経路 (後処理あり; 緑) を重畳表示している。

図 11(a), (b) は、曲がり角や折り返しに近い状況で経路が大きく方向転換する例であり、画像認識モデルの推定経路 (後処理なし) が LLM の出力経路から大きく逸脱した。このような非直線的な経路形状を含む状況は、直線通路を前提としたデータに比べて視覚的・幾何学的条件が異なるため、学習データにおける当該シチュエーションの不足が推定誤差を増大させた可能性がある。したがって、曲がり角、T 字路、折り返し、狭隘部などを含む状況を追加し、データの多様性を高めることが有効と考えられる。

一方、図 11(c), (d) は、そもそも LLM の出力経路 (教師信号) 自体が好ましくない例である。本節の評価は LLM の出力経路に対する再現性を測るため、LLM が不適切な経路を生成した場合には、画像認識モデルの推定が妥当であっても誤差が大きく計測され得る。このため、大誤差サンプルには「画像認識モデルの推定不良」だけでなく、「教師信号 (LLM の出力経路) の品質」の問題が混在していると解釈できる。

以上より、本節で観測された大きな誤差は、(1) 曲がり角・折り返し等を十分に含まない学習データのシチュエーション不足に起因する推定破綻と、(2) 教師信号である LLM の出力経路自体が好ましくないことに起因する誤差の混入、の 2 点が主要な要因であると考えられる。今後は、曲がり角・折り返しを含む状況を追加して学習データの分布を拡充するとともに、LLM の出力経路に対して品質チェックを行い、明らかに不適切な経路 (例: 不自然な折れ曲がり、通行可能領域からの逸脱) を除外した上で蒸留を行うことで、外れ値を含む大誤差の低減が期待できる。




図 10: 誤差分布の比較 (robot 用モデル)

7.3 リアルタイム性評価

本節では、提案手法の実行時運用を想定し、(i) LLM API による推論と、(ii) 蒸留により得た学習済み画像認識モデルの推論について、実行時間を比較する。特に、本研究では実行時に 10 Hz 程度で補正後 waypoint 列を更新し追従する構成を想定しているため、推論時間がその周期制約に対して十分に小さいかを確認する。

7.3.1 実験方法

LLM と画像認識モデルの推論時間を、actor 用と robot 用の 2 条件で計測した。LLM は Gemini 2.5 Pro を用い、actor 用プロンプトおよび robot 用プロンプトをそれぞれ 500 回ずつ実行し、各回の応答取得までの経過時間を計測した（API 呼び出しを含む end-to-end の時間）。

画像認識モデルについては、actor 用モデルおよび robot 用モデルを、(1) シミュレーション用デスクトップ PC、(2) 実機用ノート PC の 2 環境でそれぞれ 500 回ずつ推論し、各回の推論処理時間を計測した。デスクトップ PC / ノート PC の計算機構成は第 2 章に示すとおりである。なお、画像認識モデルの計測値はローカル環境での推論時間であり、LLM の計測値はネットワーク通信およびサーバ側処理を含む。

評価指標として、平均、標準偏差、および 95 パーセンタイル (p95) を算出し、比較した。また、LLM の平均推論時間を基準として、画像認識モデルの平均推論時間が何倍高速であるかを示した。ただし、LLM は通信・サーバ側処理を含む end-to-end 時間であり、画像認識モデルはローカル推論時間であるため、倍率は実運用時の呼び出し形態に依存する参考値である。

7.3.2 結果と考察

表 5 に推論時間の統計量を示す。LLM は平均で約 20–22 s 程度を要したのに対し、画像認識モデルはデスクトップ PC で約 1.6–1.7 ms、ノート PC で約 2.1 ms であった。また、画像認識モデ




図 11: 誤差の大きい外れ値サンプルの代表例. 入力画像上に, LLM の出力経路 (GT; 赤), 入力経路 (青), 画像認識モデルの推定経路 (後処理なし; オレンジ), および行方向平滑化後の推定経路 (後処理あり; 緑) を重畳表示した.

ルはデスクトップ PC で LLM 比約 1.3 万倍, ノート PC で約 1 万倍高速であった. また, actor 用 / robot 用の条件差は, LLM・画像認識モデルのいずれにおいても小さかった.

表 5 より, 画像認識モデルの推論時間は最大でも数 ms 程度であり, 10 Hz 程度の更新周期を仮定した実行時要件に対して十分に小さい. 一方で, LLM (Gemini 2.5 Pro) の推論時間は平均で 20s を超え, p95 では 30s 超となるため, 実行時に逐次呼び出して経路補正を行う用途には適さない. 以上の推論時間の差は, LLM をオフラインで用い, 実行時は画像認識モデルで代替するという方針が合理的であることを示す.

また, actor 用 / robot 用の条件間で推論時間の差が小さいことから, 入力構成の違い (プロンプト差分, モデル差分) は計算量の支配要因ではなく, LLM では通信・サーバ処理, 画像認識モデルでは推論基盤 (PC 性能) に主に依存していると解釈できる. デスクトップ PC とノート PC の差は 0.4-0.5 ms 程度であり, 実機環境でもリアルタイム処理に十分な余裕がある.

表 5: 推論時間の比較 (500 回計測)

	LLM [s]		Desktop [ms]		Laptop [ms]	
	actor	robot	actor	robot	actor	robot
平均	20.73	21.93	1.62	1.69	2.08	2.12
標準偏差	7.38	5.80	0.08	0.15	0.07	0.07
p95	34.07	33.20	1.73	1.96	2.24	2.27
平均速度倍率 (LLM 比)	×1	×1	×12808	×13009	×9946	×10330




図 12: actor 挙動に対する主観評価実験の様子

7.4 actor 挙動に対する主観評価

本節では、シミュレーション環境においてすれ違い場面を構成し、画像認識モデルを用いた actor 挙動が、従来の Social Force Model (SFM) と比較して主観的にどのように評価されるかを調査する。評価は、すれ違う相手 (actor) の「安全性と効率」、「配慮と主体性」、および「予測可能性と機敏さ」という観点から行う。これらは、回避距離を大きく取れば安全性は高まる一方で効率が低下し得るなど、すれ違い挙動に内在するトレードオフのバランスを評価できるように設定した。実験の様子を図 12 に示す。

7.4.1 実験方法

被験者 被験者は研究室内の学生 7 名とした。

環境・課題 シミュレーション環境として、幅 2m の直線通路を用いた。被験者はゲームコントローラにより、自身が操作するエージェント（以下、操作歩行者）を操作し、通路上を直進して所定の目標位置へ移動する。一方、通路の反対側から actor が操作歩行者に向かって接近し、両者が 1 回すれ違う状況を構成した。試行は、開始時に両者が約 10m 程度離れた位置に配置された状態

から開始し、すれ違い後に一定距離だけ離れた時点で終了とした。シミュレーション内に追加障害物は配置しない。なお、actor の最大移動速度は 1 m/s とした。

比較条件・試行数 比較条件は、すれ違い相手である actor の挙動生成手法として、(i) SFM, (ii) 画像認識モデル（提案手法）の 2 条件とした。各被験者は各条件を 1 回ずつ実施し、合計試行数は $7 \times 2 = 14$ とした。

事前練習 被験者には実験前に、操作方法および視点映像に慣れるためのテスト操作時間を設けた。テスト操作では actor を出現させず、通路内を自由に移動して操作に習熟できるようにした。なお、テスト操作中のデータは評価対象としない。

主観評価項目 各試行終了後、被験者は 5 段階リッカート尺度（5：非常にそう思う，1：全くそう思わない）でアンケートに回答した。設問は以下の 6 項目とし、相手（actor）の挙動に対する印象を評価した。

- Q1：相手（actor）は、自分の存在を認識し、配慮して動いていると感じた。
- Q2：相手が安全を確保する動きをした結果として、自分の進路や動きが妨げられたと感じた。
- Q3：相手は、こちらに道を譲ろうとしていると感じた。
- Q4：相手は、必要以上に遠回り・減速していると感じた。
- Q5：相手の進路や動きは、ゆっくりで分かりやすく、事前に予測しやすかった。
- Q6：相手の動きは、素早く機敏だったが、次にどう動くか分かりにくかった。

なお、Q2、Q4、Q6 は否定的内容を含むため、以降の集計ではスコアを反転し、全項目で「高い値ほど望ましい評価」となるよう正規化した。

7.4.2 結果と考察

図 13 に、SFM と画像認識モデルの 2 条件における各設問（Q1–Q6）の回答分布を示す。なお、Q2、Q4、Q6 は否定的内容を含むため、図の作成に際してスコアを反転し、全項目で「高い値ほど望ましい評価」となるよう正規化して表示した。

反転後スコアの平均値を比較すると、画像認識モデルは Q4 を除く全項目（Q1、Q2、Q3、Q5、Q6）において SFM を上回った。すれ違い相手が「自分の存在を認識し配慮している」（Q1）、「安全を確保しつつも進路を妨げない」（Q2）、「道を譲ろうとしている」（Q3）、「事前に予測しやすい挙動である」（Q5）、「次の動きが分かりにくいと感じにくい」（Q6）という評価が総じて改善していることから、提案する画像認識モデルは、SFM と比較して被験者にとって受け入れられやすい回避挙動を生成できた可能性がある。特に、Q1 と Q5 が高い傾向は、画像認識モデルの挙動が「相手を認識して配慮している」「動きの意図が読み取りやすい」として知覚されたことを示唆する。

一方で、Q3 と Q4 は本実験で想定したトレードオフ（配慮と主体性）の関係が比較的明確に現れた。画像認識モデルでは Q3（道を譲ろうとしている）が改善する一方で、Q4（必要以上に遠回り・減速している）は SFM より低下した。これは、回避の際により保守的な側方回避や速度抑制を選択した結果、被験者が「譲ってくれている」と感じる反面、その代償として「遠回り・減速」という効率面のコストを知覚したためと解釈できる。すなわち、Q3–Q4 の設問対は、すれ違い挙




図 13: actor 挙動に対する主観評価結果 ($n = 7$)。Q2, Q4, Q6 は反転し、高い値ほど望ましい評価となるよう正規化して表示した。

動に内在するトレードオフのバランスを評価する意図で設計したものであり、本結果は、当該トレードオフが実際の主観評価として観測され得ることを示している。

これに対し、Q1-Q2 (安全性と効率) および Q5-Q6 (予測可能性と機敏さ) では、想定したトレードオフが必ずしも明確には現れなかった。すなわち、画像認識モデルは配慮 (Q1) や予測可能性 (Q5) を高めつつ、進路妨害感 (Q2) や分かりにくさ (Q6) を増加させていない傾向が見られた。本実験は幅 2m の直線通路で障害物を配置せず、単回のすれ違いを評価対象としているため、保守的な回避 (早めの側方回避や一定の距離確保) が、被験者にとって必ずしも「邪魔」あるいは「分かりにくい」として知覚されない範囲に収まった可能性がある。その結果、設問対として意図したトレードオフが顕在化しにくい条件設定であったことが考えられる。一方で、より狭い通路や障害物の存在により回避余地が小さい状況、あるいは複数回の回避が連続する状況では、回避の保守性が効率低下や相互干渉として知覚され、トレードオフがより明確に現れる可能性がある。

画像認識モデルが高い評価を得た要因としては、視覚入力に基づく局所経路補正により、すれ違い相手 (被験者が操作する歩行者) を早い段階で認識して回避を開始する挙動になりやすい点が挙げられる。このような「前倒しの回避」は、被験者からは配慮 (Q1) や予測可能性 (Q5) として知覚されやすい一方で、回避量が過大となる場合には遠回り・減速 (Q4) として知覚され得る。したがって、本結果は、提案手法が主観的な受容性を向上させる一方で、効率面のコスト (特に Q4) を伴い得ることを示している。

ただし、本評価は被験者数が 7 名であり、各条件 1 試行と少ないため、個人差や操作のばらつきの影響を受けうる。また、障害物のない直線通路での単回すれ違いに限定しているため、複雑環境 (障害物あり、狭隘部、複数歩行者) に対する一般性については慎重に解釈する必要がある。

以上より、提案する画像認識モデルは、SFM と比較して「配慮している」「予測しやすい」といった主観評価を改善する可能性を示した一方で、「過度な遠回り・減速」(Q4) として知覚される効率コストが課題として残った。今後は、回避開始距離、側方オフセット、および速度プロファイ



図 14: ロボット挙動に対する主観評価実験の様子

ル（減速量の上限等）を調整し、「譲る印象（Q3）」を維持しつつ「必要以上の遠回り・減速（Q4）」を抑える設計が求められる。また、主観評価と併せて、回避開始距離、最小相対距離、速度低下量などの定量指標を同時に計測することで、主観的印象と運動学的特性の対応関係をより明確にできると考えられる。

7.5 ロボット挙動に対する主観評価

本節では、実機環境におけるすれ違い場面を構成し、提案する画像認識モデルを用いたロボット挙動が、従来手法（move_base）と比較して主観的にどのように評価されるかを調査する。評価は、すれ違う相手（ロボット）の「安全性と効率」、「配慮と主体性」、および「予測可能性と機敏さ」という観点から行う。これらは、回避距離を大きく取れば安全性は高まる一方で効率が低下し得るなど、すれ違い挙動に内在するトレードオフのバランスを評価できるように設定した。実験の様子を図 14 に示す。

被験者 被験者は研究室内の学生 7 名とした。

環境・課題 実機環境として、幅約 2m の廊下を用いた。被験者は廊下上を普段どおりの歩行速度で直進し、ロボットと 1 回すれ違う課題を行った。試行は、開始時に被験者とロボットが約 5m 程度離れた位置に配置された状態から開始し、すれ違い後に一定距離だけ離れた時点で終了とした。なお、ロボットの移動速度は 0.2m/s に設定した。

比較条件・試行数 比較条件は、ロボットの移動制御手法として、(i) move_base（従来手法）、(ii) 画像認識モデル（提案手法）の 2 条件とした。各被験者は各条件を 1 回ずつ実施し、合計試行数




図 15: ロボット挙動に対する主観評価結果 ($n = 7$)。Q2, Q4, Q6 は反転し、高い値ほど望ましい評価となるよう正規化して表示した。

は $7 \times 2 = 14$ とした。

主観評価項目 各試行終了後、被験者は 5 段階リッカート尺度 (5: 非常にそう思う, 1: 全くそう思わない) でアンケートに回答した。設問は以下の 6 項目とし、相手 (ロボット) の挙動に対する印象を評価した。

- Q1: 相手 (ロボット) とすれ違う際に、不安や怖さを感じることはなかった。
- Q2: 相手が安全を確保する動きをした結果として、自分の進路や動きが妨げられたと感じた。
- Q3: 相手は、こちらに道を譲ろうとしていると感じた。
- Q4: 相手は、必要以上に遠回り・減速していると感じた。
- Q5: 相手の進路や動きは、ゆっくりで分かりやすく、事前に予測しやすかった。
- Q6: 相手の動きは、素早く機敏だったが、次はどう動くか分かりにくかった。

なお、Q2, Q4, Q6 は否定的内容を含むため、以降の集計ではスコアを反転し、全項目で「高い値ほど望ましい評価」となるよう正規化した。

7.5.1 結果と考察

図 15 に、move_base と画像認識モデルの 2 条件における各設問 (Q1-Q6) の回答分布を示す。なお、Q2, Q4, Q6 は否定的内容を含むため、図の作成に際してスコアを反転し、全項目で「高い値ほど望ましい評価」となるよう正規化して表示した。

ロボット挙動に対する主観評価では、設問対として意図したトレードオフの関係が概ね明確に現れた。すなわち、「安全性と効率（Q1-Q2）」「配慮と主体性（Q3-Q4）」「予測可能性と機敏さ（Q5-Q6）」の各観点において、一方の評価が高いほど、他方に対応するコスト側の評価も同時に知覚される傾向が見られた。このことは、対人すれ違いにおけるロボット挙動が、単純に「良い／悪い」で評価されるのではなく、安全性・受容性の向上と引き換えに効率や主体性が低下し得るという構造を持つことを示している。

まず Q1-Q2（安全性と効率）について、不安や怖さを感じにくい（Q1）という評価が得られる一方で、安全確保の結果として進路や動きが妨げられたと感じる（Q2）という評価も現れている。これは、ロボットが被験者との距離確保や譲歩的な回避を優先した結果、被験者にとっては「安心できる」一方で「自分の進路自由度が制限された」として知覚された可能性を示唆する。すなわち、心理的安全性を高める挙動は、状況によっては被験者側の効率（通行の自由度）に関するコストとして現れ得る。

次に Q3-Q4（配慮と主体性）では、ロボットがこちらに道を譲ろうとしている（Q3）という印象と、必要以上に遠回り・減速している（Q4）という印象が同時に観測されている。この結果は、ロボットが人を優先する行動として速度を落としたり進路を大きく避けたりするほど、被験者には配慮として肯定的に受け取られる反面、その譲歩が「過度な減速・遠回り」として知覚され得ることを示す。したがって、本観点では「受容性を高めるための譲歩」が「主体性・効率の低下」と表裏一体であるという、設問設計の意図に沿った評価構造が確認できる。

さらに Q5-Q6（予測可能性と機敏さ）については、ゆっくりで分かりやすく予測しやすい（Q5）という評価が得られる一方で、素早く機敏である（Q6）という評価は得られにくい傾向が見られる。対人場面では、ロボットの動きが人にとって理解可能であることが安心感に直結しやすいため、機敏さよりも予測可能性が優先される挙動が肯定的に評価されやすいと考えられる。その結果として、分かりやすさを担保する挙動は、機敏さという観点ではコストとして現れ得る。

以上を総合すると、本実験の主観評価は「人に配慮し、安心感を与える」方向の挙動が、「効率・主体性・機敏さ」の低下とトレードオフになり得ることを示した。しかし、本研究の目的は、ロボット側が一方的に効率を追求することではなく、物理的安全性の確保を前提として、人混在環境において人に不安や怖さを与えにくい心理的に安心できる移動を実現することにある。したがって、ロボット側に一定のコストが生じる形であっても、被験者の不安低減や予測可能性の向上として評価されている点は、本研究の狙いに沿った結果と解釈できる。

一方で、項目によっては評価のばらつきが大きい傾向も見られた。このことは、ロボットに対する被験者の期待やリスク許容度、また「譲ってほしい／譲らずに進んでほしい」といった好みが異なり、同一の挙動でも受け止め方が分かれ得ることを示唆する。さらに、両手法でばらつきが大きい項目が存在する場合、手法差だけでなく被験者側の価値観の違いが評価に影響している可能性がある。今後は、被験者数の拡充や、環境条件（通路幅、障害物の有無、複数回すれ違い）を変えた評価を通じて、トレードオフの現れ方と個人差の要因をより詳細に検証する必要がある。

7.6 実機実験における定量評価

本節では、実機環境におけるすれ違いタスクに対して、ロボットの移動に要する実行時間および移動距離を定量的に評価する。比較対象は move_base（従来手法）と画像認識モデル（提案手法）とし、両者の効率性の差を確認する。

表 6: 実機実験における定量評価 (平均 $\pm$ 標準誤差, $n = 10$)

	実行時間 [s]		移動距離 [m]	
	move_base	画像認識モデル	move_base	画像認識モデル
平均	26.037	27.887	5.026	5.152
標準誤差	0.107	0.335	0.005	0.028

7.6.1 実験方法

実機環境として幅約 2m の廊下を用い, 被験者 (歩行者) とロボットが 1 回すれ違うタスクを実施した. ロボットの制御手法として, (i) move_base, (ii) 画像認識モデルの 2 条件を用意した. 各条件につき 10 回ずつ試行し ($n = 10$), 各試行においてロボットの移動開始からタスク終了までの経過時間を実行時間として計測した. また, 同区間における走行軌跡長を移動距離として計測した. 結果は平均および標準誤差により要約した.

7.6.2 結果と考察

表 6 に, move_base と画像認識モデルの実行時間および移動距離の比較結果を示す.

表 6 より, 本実験条件下では, 画像認識モデルは move_base と比較して, 実行時間および移動距離がいずれもわずかに大きい傾向を示した. ただし, 差は小さく, 標準誤差を踏まえると両手法の効率性は概ね同程度である可能性がある. 本研究の主目的はすれ違い時の挙動品質 (主観評価) とリアルタイム性の両立にあるため, 時間・距離の定量指標において大きな悪化が生じていない点は, 提案手法の実運用上の妥当性を支持する結果と解釈できる.

8 結論

本研究は、大規模言語モデル (Large Language Model; LLM) の知識と推論能力を活用し、動的・未知障害物を含む家庭環境において移動ロボットが安全かつ自然な経路でユーザを誘導できるナビゲーションシステムの構築を目的とした。一方で、LLM を推論時に直接用いることは応答時間・計算資源の制約から現実的でないため、LLM をオフラインの教師信号生成に用い、その判断を学習済みの軽量モデルへ転移する (知識蒸留の考え方) 方針を採用した。本論文の到達目標は、(i) LLM を用いた教師信号生成と軽量モデル学習からなる経路補正の枠組みを整理し、(ii) actor に対して主観的に違和感の少ない挙動生成が可能であることを確認し、(iii) 物理的安全性は前提条件として、実機ロボットが対人場面で人に不安や怖さを与えにくい心理的安全性を備えた走行を実現できるかを、ベースライン手法との比較により検討することであった。

8.1 まとめ

第7章では、(i) から (iii) の到達目標に対応して、学習済み画像認識モデル自体の再現性能評価、LLM と画像認識モデルの推論時間比較 (リアルタイム性評価)、actor 挙動に対する主観評価、ロボット挙動に対する主観評価、および実機実験における定量評価を実施した。

まず、学習済み画像認識モデルの性能評価では、LLM が生成した経路 (各行の目標列) に対して、画像認識モデルが出力する推定経路の一致度を定量化し、LLM の判断を推論時に用いずに再現できるか (すなわち、LLM の知識・方針を適切に蒸留できたか) を検証した。その結果、actor 用・robot 用のいずれにおいても、多くのサンプルで誤差が小さい領域に分布し、許容誤差内率の観点からも一定割合が所定の誤差範囲に収まることが確認された。また、誤差の大きい外れ値を確認したところ、(i) 曲がり角・折り返しに近い状況など学習データに十分含まれないシチュエーションで推定が破綻する例と、(ii) 教師信号である LLM の出力経路自体が好ましくない例、の2種類が主要因として観察された。以上より、本研究の画像認識モデルは、少なくとも直線通路・単回すれ違いといった主要条件下において、LLM の経路生成方針を一定程度模倣できており、LLM の知識を軽量モデルへ転移するという蒸留方針の妥当性が示された。なお、行方向平滑化 (後処理) は主目的ではないが、経路形状の連続性を補助的に整える手段として位置づけられる。

次に、リアルタイム性評価では、LLM を用いる場合と画像認識モデルを用いる場合の推論時間を比較し、画像認識モデルが実時間動作に十分なレイテンシで推論可能であることを示した。これは、LLM の判断をオフラインで教師信号として生成し、推論時には軽量モデルのみを用いるという本研究方針の実用上の意義を裏付ける結果である。

さらに、主観評価 (actor / ロボット) では、すれ違い場面における「安全性と効率」「配慮と主体性」「予測可能性と機敏さ」という観点から評価項目を設定し、ベースライン (SFM / move_base) と提案手法 (画像認識モデル) を比較した。actor に対する主観評価では、多くの項目で提案手法が良好な評価を得る傾向が確認され、ロボットに対する主観評価では、安心感や予測可能性を高める一方で、効率・機敏さを犠牲にしやすいというトレードオフが観測された。これらは、提案手法が、物理的安全性の確保を前提とした上で、「人に不安や怖さを与えにくい移動」という心理的安全性を指向する設計目標に対して、一定の整合性を持つことを示している。

最後に、実機実験における定量評価では、ベースライン (move_base) と提案手法 (画像認識モデル) を比較し、実行時間および移動距離の観点から、実環境における挙動特性を定量的に示した。以上より、本研究は、LLM を教師信号生成に用いた知識転移の枠組みに基づき、すれ違いを含む状況において、主観の評価と定量評価の両面から提案手法の有効性と課題を整理した。

8.2 今後の課題と展望

本研究で得られた知見を踏まえ、今後の課題と展望を以下に述べる。

学習データセットの拡充（環境・状況の多様化） 外れ値解析で確認されたように、曲がり角や折り返しに近い経路形状など、学習データに十分含まれないシチュエーションでは推論誤差が増大し得る。したがって、直線通路・単回すれ違いに限らない環境（曲がり角、分岐、狭窄、障害物配置あり等）や、相互作用が複雑化する状況（複数回すれ違い、追い越し、密集度上昇等）を追加し、データ分布の偏りを低減することが重要である。

ドメインランダムマイゼーションとデータオーギュメンテーション 実環境適用を見据えると、カメラ視点や照明条件だけでなく、歩行者（actor）の身長、体格、服装、色、テクスチャ等の外観要因の変動に対して頑健である必要がある。そのため、シミュレーションにおけるドメインランダムマイゼーションとして、actor の外観（身長・服装・色・形状）を系統的に多様化し、背景や照明条件も含めた見えの分布を広げることが望ましい。加えて、画像変換（輝度・コントラスト変化、ぼかし、ノイズ付与、部分的隠れ等）によるデータオーギュメンテーションを併用することで、教師信号の枠組みを維持したまま汎化性能の向上が期待できる。

教師信号（LLM 経路）の品質管理 外れ値の一部は、教師信号である LLM 経路自体が好ましくないケースに起因していた。このため、蒸留の前段として、LLM 出力経路の品質を検査・フィルタリングする手続きが必要である。また、プロンプト設計の改善により、回避方針（安全優先・効率優先等）の条件を明示し、意図した評価軸に沿う経路を安定して生成させることも重要である。

評価設計の高度化 本研究の実験設定（直線通路・すれ違い 1 回）では、「配慮／安全」と「効率／主体性」のトレードオフが常に強く顕在化するとは限らないことが示唆された。今後は、トレードオフが表出しやすい条件（通路幅の縮小、速度差の増大、複数障害物の追加等）を導入し、主観評価が分岐しやすい状況を意図的に設計することで、手法間差をより明確に検証できる評価系へ発展させる必要がある。

LLM 活用の拡張（教師生成の高度化） 本研究では LLM を教師信号生成に限定して用いたが、将来的には、状況に応じた方針切替（安全重視／効率重視）を教師生成段階で体系的に作り分け、「方針条件付き蒸留」へ拡張することが考えられる。これにより、実行時は軽量モデルでありながら、ユーザや環境条件に応じた行動特性を選択できる枠組みへ発展できる可能性がある。

以上より、本研究は、LLM の推論結果を教師信号として用い、軽量な画像認識モデルへ転移することで、動的障害物を含む環境における移動ロボット・actor の行動生成を統合的に扱う枠組みを示した。今後は、データと教師信号の品質・多様性を高めることで、実環境の多様な状況に対して頑健で、人にとって安全かつ受容されるナビゲーションの実現を目指す。

謝辞

本研究の遂行ならびに本論文の執筆にあたり、ご協力いただいた全ての皆様に深く感謝申し上げます。特に、垣内教授には研究全般にわたり多大なるご指導とご助言を賜りましたこと、心より感謝申し上げます。また、本研究を進めるにあたりご指導いただいた助手の増沢さんにも、数多くの助言と支援をいただきましたことに厚く御礼申し上げます。さらに、実験の実施に際し、被験者としてご協力いただいた研究室の皆様に心より感謝申し上げます。以上、ご支援・ご協力いただいた皆様に重ねて感謝申し上げます。

参考文献

- [1] 白谷歩夢, 垣内洋平. 家庭用移動ロボットを用いた手つなぎナビゲーションシステムの開発と評価. 日本ロボット学会学術講演会予稿集 (CD-ROM), 第 42 巻, 2024.
- [2] Wei Huang, Liangliang Chen, and Peng Li. An improved gmapping algorithm and bidirectional a* path planning for indoor navigation. *IEEE Access*, 2020.
- [3] Jian Wu, et al. Uwb and 5g integrated indoor positioning for mobile robots. *Sensors*, 2021.
- [4] Emmanuel Senft, Satoru Satake, and Takayuki Kanda. Would you mind me if i pass by you?: Socially-appropriate behaviour for an omni-based social robot in narrow environment. In *Proceedings of the 2020 ACM/IEEE International Conference on Human-Robot Interaction, HRI '20*, p. 539–547. ACM, March 2020.
- [5] Dirk Helbing and Péter Molnár. Social force model for pedestrian dynamics. *Physical Review E*, 1995.
- [6] Arne Silva, et al. Social robot force model for robot navigation among humans. *IEEE RO-MAN*, 2018.
- [7] Sven Kreiss. Deep social force, 2021.
- [8] 南康太, 眞野千輝, 三浦純, 林宏太郎. アウェアネスを考慮した social force model に基づく歩行者シミュレーション. ロボティクス・メカトロニクス講演会講演概要集, Vol. 2021, pp. 1P2–G12, 2021.
- [9] Tobias Kretz, Jochen Lohmiller, and Peter Sukennik. Some indications on how to calibrate the social force model of pedestrian dynamics, 2017.
- [10] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In I. Guyon, U. Von Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, editors, *Advances in Neural Information Processing Systems*, Vol. 30. Curran Associates, Inc., 2017.
- [11] Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel M. Ziegler, Jeffrey Wu, Clemens Winter, Christopher Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sam McCandlish, Alec Radford, Ilya Sutskever, and Dario Amodei. Language models are few-shot learners, 2020.
- [12] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision, 2021.

- [13] Haotian Liu, Chunyuan Li, Qingyang Wu, and Yong Jae Lee. Visual instruction tuning, 2023.
- [14] Jinze Bai, Shuai Bai, Shusheng Yang, Shijie Wang, Sinan Tan, Peng Wang, Junyang Lin, Chang Zhou, and Jingren Zhou. Qwen-vl: A versatile vision-language model for understanding, localization, text reading, and beyond, 2023.
- [15] Geoffrey Hinton, Oriol Vinyals, and Jeff Dean. Distilling the knowledge in a neural network, 2015.
- [16] Zhihui Li, Pengfei Xu, Xiaojun Chang, Luyao Yang, Yuanyuan Zhang, Lina Yao, and Xiaojiang Chen. When object detection meets knowledge distillation: A survey. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, Vol. 45, No. 8, pp. 10555–10579, 2023.
- [17] Zaiwei Zhang, Gregory P. Meyer, Zhichao Lu, Ashish Shrivastava, Avinash Ravichandran, and Eric M. Wolff. Vlm-kd: Knowledge distillation from vlm for long-tail visual recognition, 2024.
- [18] Anthony Brohan, et al. Rt-2: Language models as robotic policy. *arXiv preprint arXiv:2307.15818*, 2023.
- [19] Gemini Robotics Team, Abbas Abdolmaleki, Saminda Abeyruwan, et al. Gemini robotics 1.5: Pushing the frontier of generalist robots with advanced embodied reasoning, thinking, and motion transfer, 2025.
- [20] Morgan Quigley, Ken Conley, Brian Gerkey, Josh Faust, Tully Foote, Jeremy Leibs, Rob Wheeler, and Andrew Y. Ng. Ros: an open-source robot operating system. In *ICRA Workshop on Open Source Software*, 2009.
- [21] Eitan Marder-Eppstein, Eric Berger, Tully Foote, Brian Gerkey, and Kurt Konolige. The office marathon: Robust navigation in an indoor office environment. In *2010 IEEE International Conference on Robotics and Automation*, pp. 300–307, 2010.
- [22] move_base — ros navigation stack documentation. <https://docs.ros.org/>. Accessed: 2026-02-02.
- [23] Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization, 2017.

A 付録：プロンプト全文

本研究における教師信号生成では、LLM として Gemini 2.5 Pro を用いた。本研究で用いたプロンプトの全文を以下に示す。

A.1 actor 用プロンプト

本プロンプトでは、`{points_str}` として補正前の参照経路（入力点列）を与える。`{points_str}` は、実行ログとして保存した JSON から `points` 配列のみを抽出し、その点列（画像座標系で正規化された $[y, x]$ ）をプロンプト内へ埋め込む文字列である。すなわち、`timestamp` や `header` 等のメタ情報はプロンプトには含めず、経路点列のみを入力として用いる。以下に、`{points_str}` に埋め込まれる入力点列の例を示す。

```
[
  { "y": 479, "x": 335 },
  { "y": 216, "x": 336 },
  { "y": 213, "x": 346 }
]
```

また、LLM の出力は、補正後経路を表す `waypoint` 列を JSON 配列として返す形式である（本文第 3.4 節）。以下に出力例を示す。

```
[
  { "point": [999, 500], "label": "0" },
  { "point": [800, 525], "label": "1" },
  { "point": [600, 575], "label": "2" },
  { "point": [500, 600], "label": "3" },
  { "point": [443, 540], "label": "4" }
]
```

以下に、actor 用の教師信号生成に用いたプロンプト全文を示す。

From the actor's first-person view in the simulation, analyze the images carefully and generate a safe walking trajectory for the actor.

You are given TWO images and a planned path:

Image 1 (First image):

A color RGB image showing the environment from the actor's viewpoint.
This is the normal camera view of the scene.

Image 2 (Second image):

A floor mask image where walkable floor regions are highlighted in green color.
Only the green regions represent walkable floor areas.

The actor's planned path (a sequence of reference points):
`{points_str}`

The points above represent a high-level intended direction and destination.

Each point is in the format `{"y": <y_value>, "x": <x_value>}`, where:

- "y" is the vertical coordinate (0-1000, normalized)
- "x" is the horizontal coordinate (0-1000, normalized)
- Both coordinates are normalized relative to the image dimensions.

Important clarification:

The given planned path is a high-level reference for direction and final destination, NOT a strict trajectory that must be followed from its first waypoint.

Your task is to generate a safe walking trajectory that generally follows the intent of the planned path while avoiding obstacles and staying strictly within walkable floor regions.

Hard constraint (must always hold):

- Every waypoint MUST lie on a walkable floor pixel in Image 2 (green region).
- If a waypoint would fall outside green, you MUST move it to the nearest green location.
- If the destination (last planned point) is outside green, choose the nearest green point to it as the final waypoint.

The output MUST strictly follow the specified JSON format.

Before deciding the trajectory, follow the reasoning steps below.

Critical clarification about the starting point:

The waypoint at $y = 999$ does NOT represent the beginning of the actor's motion. The actor is already walking before the current image frame is captured.

The image represents a snapshot of an ongoing motion, and the trajectory is assumed to already exist below the visible image region.

Therefore, the first visible waypoint at $y = 999$ may already reflect an avoidance maneuver that started earlier, outside the image.

The first visible waypoint at $y = 999$ does not need to start from the center.

If obstacles exist nearby, it is ideal to have already avoided them to the left or right beforehand.

Step 1: Environment Understanding

Analyze Image 1 (the color RGB image) to understand the environment type (e.g., corridor, open space, intersection, near a wall, etc.).

Use Image 2 (the floor mask image) to precisely identify walkable floor regions. Only green regions are walkable.

Identify walls, doors, pillars, and other structural elements in Image 1 that define the walking boundaries.

Step 2: Planned Path Analysis

Analyze the planned path points to understand the intended direction and final destination.

Check whether the planned path passes through obstacles or non-floor regions. Identify unsafe or infeasible segments of the planned path.

Remember that the first point of the planned path does NOT represent the actor's actual starting position and does not need to be reached or matched.

Step 3: Object and Obstacle Recognition

Detect all obstacles visible on the floor in Image 1, including robots, humans, furniture, and other movable or fixed objects.

Treat the following as non-walkable regions that must always be avoided:

- Walls
- Doors
- Pillars

Robots and humans must be treated as dynamic obstacles.
Assume they may move unpredictably in the near future.

Use Image 2 (the floor mask image) to ensure that all waypoints lie strictly on walkable floor regions.

Step 4: Safe Path Planning Logic

Generate a safe trajectory that satisfies ALL of the following conditions:

- The trajectory MUST start at $y = 999$ (the bottom edge of the image), representing the actor's current position.
- The trajectory should be generated in a bottom-to-top manner, representing forward walking from the actor's viewpoint.
- The trajectory does NOT need to pass through or align with the first point of the planned path.
- The planned path is a high-level reference for direction and destination only.
- The trajectory MUST end exactly at the last point of the planned path, which represents the intended destination.
- The trajectory should follow the general direction and intent of the planned path as closely as possible.
- Deviate from the planned path only when necessary to ensure safety.

Obstacle avoidance rules:

- Walls, doors, and pillars are static obstacles and must never be crossed or touched.
- Robots and humans must be treated as dynamic obstacles with potential future motion.
- The trajectory must proactively and conservatively avoid robots and humans.
- Even if robots or humans are not currently blocking the path, regions near them should be avoided in advance.
- A path that passes close to a robot or a human, even without immediate collision, must be considered unsafe and avoided.
- Maintain a sufficiently large safety margin around all robots and humans at all times, anticipating their possible future movement.

If the planned path passes through unsafe regions or obstacles:

- Generate a safe detour around those regions.
- After passing the unsafe area, return to the original path direction when safe.
- Ensure smooth and continuous transitions between path segments.

Step 5: Verification

After generating the trajectory, verify that every waypoint:

- Lies on a green (walkable) region in Image 2.

- Does not overlap with or pass close to any obstacle visible in Image 1.
- Maintains sufficient clearance from robots and humans.
- Forms a smooth, continuous walking trajectory.
- Starts at $y = 999$ and ends exactly at the last point of the planned path.

If any waypoint violates these conditions, regenerate the path.

If you are unsure whether a point is on green, be conservative and move it inward into the green region.

----- Step 6: Output Format

Output ONLY the list of waypoints representing the safe walking trajectory.
Do NOT include any explanations or extra text.

IMPORTANT: Output must be valid JSON only (no markdown fences, no extra keys).

Each waypoint must have:

- "point": a coordinate pair $[y, x]$, normalized to 0-1000
- "label": a sequential string label starting from "0"

The first waypoint ("label": "0") MUST be located at $y = 999$.

The final waypoint MUST exactly match the last point of the planned path.

Output format example:

```
[
  {"point": [999, 500], "label": "0"},
  {"point": [850, 520], "label": "1"},
  {"point": [700, 540], "label": "2"},
  {"point": [550, 560], "label": "3"}
]
```

A.2 robot 用プロンプト

本プロンプトでは、`{points_str}` として補正前の参照経路（入力点列）を与える。`{points_str}` は、実行ログとして保存した JSON から `points` 配列のみを抽出し、その点列（画像座標系で正規化された $[y, x]$ ）をプロンプト内へ埋め込む文字列である。すなわち、`timestamp` や `header` 等のメタ情報はプロンプトには含めず、経路点列のみを入力として用いる。以下に、`{points_str}` に埋め込まれる入力点列の例を示す。

```
[
  { "y": 479, "x": 315 },
  { "y": 402, "x": 315 },
  { "y": 290, "x": 286 },
  { "y": 223, "x": 259 },
  { "y": 180, "x": 219 },
  { "y": 147, "x": 193 },
  { "y": 122, "x": 181 },
  { "y": 102, "x": 172 },
  { "y": 86, "x": 166 },
  { "y": 73, "x": 160 },
  { "y": 62, "x": 155 },
  { "y": 52, "x": 151 },
  { "y": 44, "x": 148 },
]
```

```
[
  { "y": 37, "x": 144 },
  { "y": 31, "x": 142 },
  { "y": 26, "x": 139 },
  { "y": 21, "x": 137 },
  { "y": 16, "x": 136 },
  { "y": 13, "x": 134 },
  { "y": 11, "x": 133 }
]
```

また、LLM の出力は、補正後経路を表す waypoint 列を JSON 配列として返す形式である（本文第 3.4 節）。以下に出力例を示す。

```
[
  { "point": [999, 650], "label": "0" },
  { "point": [850, 640], "label": "1" },
  { "point": [700, 625], "label": "2" },
  { "point": [550, 600], "label": "3" },
  { "point": [400, 550], "label": "4" },
  { "point": [250, 420], "label": "5" },
  { "point": [150, 310], "label": "6" },
  { "point": [ 80, 250], "label": "7" },
  { "point": [ 22, 207], "label": "8" }
]
```

以下に、robot 用の教師信号生成に用いたプロンプト全文を示す。

```
From the robot's first-person view in the real environment, analyze the images carefully
and generate a safe navigation trajectory for the robot.

You are given TWO images and a planned path:

Image 1 (First image):
A color RGB image showing the environment from the robot's viewpoint (real-world camera
feed).
This is the normal camera view of the scene.

Image 2 (Second image):
A floor mask image where walkable floor regions are highlighted in green color.
Only the green regions represent walkable floor areas.

The robot's planned path (a sequence of reference points):
{points_str}

The points above represent a high-level intended direction and destination.
Each point is in the format {"y": <y_value>, "x": <x_value>}, where:
- "y" is the vertical coordinate (0-1000, normalized)
- "x" is the horizontal coordinate (0-1000, normalized)
- Both coordinates are normalized relative to the image dimensions.

Important clarification:
The given planned path is a high-level reference for direction and final destination,
NOT a strict trajectory that must be followed from its first waypoint.

Your task is to generate a safe navigation trajectory that generally follows the intent
of the planned path
while avoiding obstacles and staying strictly within walkable floor regions.

Hard constraint (must always hold):
```

- Every waypoint MUST lie on a walkable floor pixel in Image 2 (green region).
- If a waypoint would fall outside green, you MUST move it to the nearest green location.
- If the destination (last planned point) is outside green, choose the nearest green point to it as the final waypoint.

Robot-specific safety requirements:

- The robot must keep extra clearance from humans at all times.
- Humans are dynamic obstacles; assume they can move unpredictably.
- Prefer paths that pass behind humans only if there is large clearance; otherwise detour early.
- If a safe floor-only path that reaches the exact destination is not possible, choose the closest reachable point on green to the destination.

The output MUST strictly follow the specified JSON format.

Before deciding the trajectory, follow the reasoning steps below.

Critical clarification about the starting point:

The waypoint at $y = 999$ represents the robot's current position at the bottom edge of the image.

It does NOT need to be centered.

If obstacles (especially humans) are close by, it is acceptable that the robot is already offset left/right.

----- Step 1: Environment Understanding

Analyze Image 1 (the color RGB image) to understand the environment type (e.g., corridor, open space, intersection, near a wall, etc.).

Use Image 2 (the floor mask image) to precisely identify walkable floor regions. Only green regions are walkable.

Identify walls, doors, pillars, and other structural elements in Image 1 that define the walking boundaries.

----- Step 2: Planned Path Analysis

Analyze the planned path points to understand the intended direction and final destination.

Check whether the planned path passes through obstacles or non-floor regions. Identify unsafe or infeasible segments of the planned path.

Remember that the first point of the planned path does NOT represent the robot's actual starting position and does not need to be reached or matched.

----- Step 3: Object and Obstacle Recognition

Detect all obstacles visible on the floor in Image 1, including humans, other robots, furniture, and other movable or fixed objects.

Treat the following as non-walkable regions that must always be avoided:

- Walls

- Doors
- Pillars

Humans must be treated as dynamic obstacles.
 Assume they may move unpredictably in the near future.
 Other robots may also move; avoid them conservatively.

Use Image 2 (the floor mask image) to ensure that all waypoints lie strictly on walkable floor regions.

----- Step 4: Safe Path Planning Logic

Generate a safe trajectory that satisfies ALL of the following conditions:

- The trajectory MUST start at $y = 999$ (the bottom edge of the image), representing the actor's current position.
- The trajectory should be generated in a bottom-to-top manner, representing forward walking from the actor's viewpoint.
- The trajectory does NOT need to pass through or align with the first point of the planned path.
- The planned path is a high-level reference for direction and destination only.
- The trajectory MUST end exactly at the last point of the planned path, which represents the intended destination.
- The trajectory should follow the general direction and intent of the planned path as closely as possible.
- Deviate from the planned path only when necessary to ensure safety.

Obstacle avoidance rules:

- Walls, doors, and pillars are static obstacles and must never be crossed or touched.
- Humans must be treated as dynamic obstacles with potential future motion.
- The trajectory must proactively and conservatively avoid humans.
- Even if humans are not currently blocking the path, regions near them should be avoided in advance.
- A path that passes close to a human, even without immediate collision, must be considered unsafe and avoided.
- Maintain a sufficiently large safety margin around humans at all times, anticipating their possible future movement.

Robot motion constraints:

- Prefer smooth, low-curvature paths (avoid sharp zig-zags).

If the planned path passes through unsafe regions or obstacles:

- Generate a safe detour around those regions.
- After passing the unsafe area, return to the original path direction when safe.
- Ensure smooth and continuous transitions between path segments.

----- Step 5: Verification

After generating the trajectory, verify that every waypoint:

- Lies on a green (walkable) region in Image 2.
- Does not overlap with or pass close to any obstacle visible in Image 1.
- Maintains sufficient clearance from robots and humans.
- Forms a smooth, continuous walking trajectory.
- Starts at $y = 999$ and ends exactly at the last point of the planned path.

If any waypoint violates these conditions, regenerate the path.

If you are unsure whether a point is on green, be conservative and move it inward into the green region.

Step 6: Output Format

Output ONLY the list of waypoints representing the safe walking trajectory.
Do NOT include any explanations or extra text.

IMPORTANT: Output must be valid JSON only (no markdown fences, no extra keys).

Each waypoint must have:

- "point": a coordinate pair [y, x], normalized to 0-1000
- "label": a sequential string label starting from "0"

The first waypoint ("label": "0") MUST be located at y = 999.

The final waypoint MUST exactly match the last point of the planned path.

Output format example:

```
[
  {"point": [999, 500], "label": "0"},
  {"point": [850, 520], "label": "1"},
  {"point": [700, 540], "label": "2"},
  {"point": [550, 560], "label": "3"}
]
```

B 予備審査時の質疑への回答

Q1. 「LLM」と書いてあるが、言語で何かをするのではなく、VLM を使っているのではないか。(栗山先生)

A1. 本論文では、用語として LLM を広義に用い、視覚入力を統合した VLM を含むものとして扱います。したがって、視覚情報（画像やマスク）とテキスト情報を同時に入力して推論・生成を行うモデルについても、統一して LLM と表記します。ただし、実際に使用しているモデルは、視覚と言語を統合する VLM に該当します。

Q2. LLM によって補正されるのは何か。(栗山先生)

A2. LLM によって補正されるのは、補正前に与える経路（waypoint 列）です。具体的には、視点カラー画像や床領域マスクなどの入力に基づいて、安全な通行を満たすように waypoint の配置を調整し、補正後の経路（waypoint 列）を生成します。LLM の入出力は本文第 3.2 節（入力情報の設計）および第 3.4 節（出力形式の設計）に示しています。

Q3. VLM は障害物を避けるはずだ、という前提があるのか。(栗山先生)

A3. 前提として「VLM は必ず障害物を避けるはずだ」と仮定しているわけではありません。本研究では、障害物を避けることを目的としてプロンプトに明示し、床領域マスク上に waypoint を配置することなどの制約を与えたうえで、実際に出力が安全な回避経路になっているかを試行により確認しています。プロンプトの設計意図は本文第 3.3 節（プロンプト設計）に、出力の例は本文第 3.4 節（出力形式の設計）の図 6 に示しています。

Q4. VLM での経路生成は、どのように行っているのか。(栗山先生)

A4. VLM での経路生成は、視点カラー画像と床領域マスクを画像として入力し、補正前経路の点列をテキストとして追加入力するマルチモーダル推論によって行っています。生成時には、経路生成の目的（安全な通行）と出力 JSON 形式を明示し、床領域マスク上に waypoint を配置することを必須条件として与えることで、通行可能領域からの逸脱を抑制しています。設計意図は、本文第 3.3 節（プロンプト設計）に示しています。また、本研究で用いたプロンプトの全文は付録 A に示しています。

Q5. LLM は時系列に弱いですが、時間的に一貫した動作になるのか。ノイズ的な動きになることは問題ではないのか。(栗山先生)

A5. 本研究では、LLM（VLM）をオンライン制御そのものに用いるのではなく、視覚入力と補正前経路に基づいて補正後経路（waypoint 列）を生成する用途（教師信号生成）として用いています。このため、LLM が逐次的に時系列制御を行い、時間的に一貫した動作を継続的に出力することは前提としていません。また、本研究では推論を 0.1 秒間隔で実行しており、回避経路を推論してから実際にすれ違いが生じるまでには一定の時間が存在します。そのため、回避対象から十分離れた位置で一時的に経路が揺らぐ（ノイズ的な変動が生じる）場合でも、すれ違い直前の段階では再推論によって経路が更新されるため、安全な回避行動の成立に対する影響は限定的であると考えています。少なくとも本研究の実験条件では、この点が評価上の問題として顕在化しませんでした。LLM の位置づけは本文第 3.1 節（教師信号生成における LLM 利用の位置づけ）に示しています。

Q6. リアルな動きのシミュレーションを作るという目的に対して、これがリアルであることをど

のように評価するのか. LLM がリアルを表しているかということ、どのように示すのか. (三浦先生)

A6. 本研究では、「リアル」を物理的忠実度（現実の人間運動の再現性）として厳密に同定するのではなく、すれ違い場面において観察者が違和感なく受け入れられるか、という観点で評価します. 具体的には、被験者による評価を通じて、回避行動が不自然でないか、配慮が感じられるかなどを確認して、シミュレーション内の動きが目的に照らして十分に妥当であるかを判断します. また、本研究では、LLM が現実そのものを忠実に表現していることを直接主張するのではなく、LLM (VLM) を教師信号生成器として用いることで、人が見て違和感の少ない回避経路や行動が生成されるかを評価によって示します. 主観評価については、第 7 章の第 7.4 節 (actor 挙動に対する主観評価) および第 7.5 節 (ロボット挙動に対する主観評価) で結果を示しています.

Q7. ロボットの動きを作るときは環境に対して最適化できるため、環境が良かったとは評価できないのではないか. (三浦先生)

A7. ご指摘の通り、ロボットの評価を行う際に、ロボット側が特定の環境 (actor) に適合した結果だけを見てしまうと、「環境が良かった」とは評価しにくくなります. 予備審査時点では、actor をロボット評価のための環境作成に用いるという位置づけであったため、actor の評価もしないといけないのではないかと、あるいはロボットが作成した actor に合わせただけになっていないか、という懸念が生じ得ます. これに対して本論文では、actor とロボットを別の対象として扱い、actor の評価 (シミュレーション) とロボットの評価 (実機) を分離し、それぞれ独立に評価しています. 具体的には、actor はシミュレーション環境において actor 同士 (例: SFM と提案手法) で比較し、主観評価により挙動の自然さ等を評価します. 一方でロボットは実機環境において手法同士 (例: move.base と提案手法) を比較し、移動の成立や挙動指標、および主観評価から性能を評価します. このように、actor とロボットはそれぞれ独立に評価しています. actor モデルの設計は本文第 5.4 節 (比較対象 2: 画像認識モデルによる経路補正 actor)、ロボット制御モデルの設計は第 6.4 節 (比較対象 2: 画像認識モデルによる局所経路補正ナビゲーション) に示しています. それぞれの評価は、第 7.4 節 (actor 挙動に対する主観評価) および第 7.5 節 (ロボット挙動に対する主観評価) に示しています.

Q8. ロボット制御モデルはどのように作るのか. (三浦先生)

A8. 本研究では、ロボット制御全体を生成モデルで置き換えるのではなく、既存のナビゲーション系を前提に、視覚入力に基づく局所的な経路修正として組み込みます. 具体的には、LLM が生成した補正後経路 (座標列) を教師ラベルとして用い、視点カラー画像 (RGB) と入力パスマスク (補正前経路) を入力として補正後経路を推定する画像認識モデルを教師あり学習で作ります. 実行時には、学習したモデルを推論して得られた補正後 waypoint 列を生成し、これを追従してロボットを走行させます. この手順は本文第 4 章 (画像認識モデルの学習) および第 6.4 節 (比較対象 2: 画像認識モデルによる局所経路補正ナビゲーション) に示しています.

Q9. シミュレーションモデルを作る話とロボット制御を作る話で LLM を両方使うとすると、それらは別物ではないか. (三浦先生)

A9. いただいたコメントの通り、目的と評価系が異なるため、別物として扱います. 予備審査時点では、actor をロボット評価のための環境要素として位置づけていました. これに対して本論文では、actor とロボットを別ものとして扱い、目的と評価系を分離して整理しています. ただし、い

ずれも LLM (VLM) を教師信号生成に用い, その出力を教師ラベルとして学習した軽量モデルを実行時に用いる, という方法論を共有しています. これらの位置づけは本文第 1.1 節 (研究の背景と目的) および第 5.1 節 (actor の役割と設計方針), 6.1 節 (ロボットの役割と設計方針) に示しています.